

Tema 8: Clasificación binaria (Activación softmax)

En este apartado se describe un problema de clasificación binaria empleando un modelo de hipótesis basado en polinomios de grado g así como una única función de activación llamada *Softmax*. Cuando una hipótesis usa funciones de activación sigmoideas, el calculo del k -esimo valor de salida $P_k^{(i)}$ ($\forall k \in [0, S - 1]$) solo depende del resultado parcial $z_k^{(i)}$, lo cual significa que solo el conjunto de valores de entrada $\mathbf{x}$ es el único elemento común en el calculo de cada valor $P_k^{(i)}$. Debido a que el resultado $P_k^{(i)}$ solo depende de $z_k^{(i)}$, es posible obtener valores similares o iguales en dos o mas salidas de la hipótesis, lo que puede dificultar la interpretación del resultado de clasificación. En este sentido, la función de activación softmax es empleada para generar las salidas $P_k^{(i)}$ tal que su suma sea igual a uno. De esta manera se tiene un 100% de probabilidad repartido entre las S salidas de la hipótesis, teniendo que, idealmente, solo uno de los valores P alojaría el 100% de la probabilidad mientras que el resto indicarían un porcentaje de 0%. Entendiendo que la clase que se asigna a la muestra que ingresa a la hipótesis es la posición k donde se encuentra el valor de probabilidad P mas alto. Así, la interpretación de la clasificación dada por la hipótesis es mas fácilmente interpretable y, en principio, directamente comparable con los objetivos T . Para este apartado se toma como referencia el conjunto de muestras ilustrado en la [Figura 1](#).




Figura 1: Conjunto tomado como ejemplo para un problema de clasificación binaria empleando la función de activación softmax. Este conjunto de muestras esta etiquetado para dos clases.

La función de activación softmax recibe como entrada los resultados $z_k^{(i)}$ de los $S - 1$ polinomios $f(\mathbf{x}^{(i)})$ para generar las S predicciones correspondientes a las S clases del conjunto de muestras a clasificar. Entonces la función softmax se expresa como:

$$P_k^{(i)} = g(z_0^{(i)}, z_1^{(i)}, \dots, z_{S-1}^{(i)}) = \frac{e^{z_k^{(i)}}}{\sum_{d=0}^{S-1} e^{z_d^{(i)}}} \quad (1)$$

y a partir de cada predicción $P_k^{(i)}$ es posible calcular un costo C_k considerando todas las muestras, tal como se lo indica la siguiente expresión:

$$C(\mathbf{P}, \mathbf{T}) = C_k = -\frac{1}{m} \sum_{i=1}^m T_k^{(i)} \log(P_k^{(i)}) \quad (2)$$

Esta Ecuación 2 denota la *Entropía Cruzada Multi Clase* (EBMC) e indica el costo considerando solo las muestras con etiqueta $T_k^{(i)} = 1$ (Clase A'). El motivo de eliminar el segundo termino con respecto a la entropía binaria cruzada recae en el hecho de que las muestras con etiqueta cero ($T_k^{(i)} = 0$) no contribuyen al costo C_k pero si lo hacen en el resto de costos, puesto que cada predicción esta asociada a un clase y por tanto, mientras una muestra tiene etiqueta uno para el calculo de un costo, también tiene etiqueta cero para el resto de cálculos de los demás costos, es decir, cada muestra tiene un número de etiquetas igual al número de clases, donde solo una etiqueta tiene un valor de uno ("1") y el resto un valor de cero ("0"). La Figura 2 representa el proceso de calculo de las predicciones $P_k^{(i)}$ y de los costos $C_k^{(i)}$.




Figura 2: Representación del proceso de calculo de las predicciones y los costos.

Como se ha mencionado, un proceso de optimización parte de una única expresión, por lo que se utiliza la suma de todos los costos por predicción para obtener:

$$C(\mathbf{P}, \mathbf{T}) = C_0 + C_1 + \dots + C_{S-1} = -\frac{1}{m} \sum_{i=1}^m \sum_{k=0}^{S-1} T_k^{(i)} \log(P_k^{(i)}) \quad (3)$$

la cual es la expresión a minimizar. Para esto, es necesario obtener las derivas de esta función con respecto a cada uno de los coeficientes $\omega_{j,k}$ ($\forall j \in [0, n], k \in [0, S-1]$). Sin embargo, para hacer mas amigable la comprensión del proceso de derivación, se ejemplifica el calculo de la derivada solo con respecto al coeficiente $\omega_{2,0}$, el cual esta resaltado en la Figura 3. Nótese como este coeficiente solo contribuye al calculo de $z_0^{(i)}$ que su vez contribuye al calculo de todas las predicciones y por tanto contribuye a todos los costos.




Figura 3: Representación del calculo de la derivada de la función de costo (Ecuación 3) con respecto al coeficiente $\omega_{2,0}$.

Así, al ser la función de costo la sumatoria de los costos por predicción, se puede derivar individualmente cada uno de los costos por predicción tal como:

$$\frac{\partial}{\partial \omega_{2,0}} C(\mathbf{P}, \mathbf{T}) = \frac{\partial C_0}{\partial \omega_{2,0}} + \frac{\partial C_1}{\partial \omega_{2,0}} + \dots + \frac{\partial C_{S-1}}{\partial \omega_{2,0}} \quad (4)$$

Para simplificar el calculo de cada derivada, se utiliza la regla de la cadena para obtener derivadas mas simples de resolver, pudiendo llegar a la siguiente expresión:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \frac{\partial C_0}{\partial P_0^{(i)}} \frac{\partial P_0^{(i)}}{\partial z_0^{(i)}} \frac{\partial z_0^{(i)}}{\partial \omega_{2,0}} + \frac{\partial C_1}{\partial P_1^{(i)}} \frac{\partial P_1^{(i)}}{\partial z_0^{(i)}} \frac{\partial z_0^{(i)}}{\partial \omega_{2,0}} + \dots + \frac{\partial C_{S-1}}{\partial P_{S-1}^{(i)}} \frac{\partial P_{S-1}^{(i)}}{\partial z_0^{(i)}} \frac{\partial z_0^{(i)}}{\partial \omega_{2,0}} \quad (5)$$

Se debe prestar atención en sobre que variable se realiza cada derivada. Por ejemplo cada costo C_k depende solo de la predicción $P_k^{(i)}$ y por ello es que se realizan las derivadas $\frac{\partial C_k}{\partial P_k^{(i)}}$. En cambio, cada predicción $P_k^{(i)}$ depende de todos los resultados $z^{(i)}$ y por tanto se deberían realizar las derivadas de $P_k^{(i)}$ con respecto a cada variable $z^{(i)}$. Aunque, en esta explicación solo se considera el coeficiente $\omega_{2,0}$, por esa razón, las derivadas de $P_k^{(i)}$ solo se realizan con respecto a $z_0^{(i)}$ ya que es la única variable que depende de $\omega_{2,0}$.

A continuación se muestra el procedimiento matemático para la obtención de cada derivada. Comenzando por por las derivadas $\frac{\partial C_k}{\partial P_k^{(i)}}$, se tiene el primer termino a resolver:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \frac{\partial C_0}{\partial P_0^{(i)}} \dots, \text{ de tal modo que:} \quad \frac{\partial C_0}{\partial P_0^{(i)}} = \frac{\partial}{\partial P_0^{(i)}} \left[-\frac{1}{m} \sum_{i=1}^m T_0^{(i)} \log(P_0^{(i)}) \right] = \boxed{-\frac{1}{m} \sum_{i=1}^m \frac{T_0^{(i)}}{P_0^{(i)}}} \quad (6)$$

mientras que la primera derivada del segundo termino: $\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \dots \frac{\partial C_1}{\partial P_1^{(i)}} \dots$ queda como:

$$\frac{\partial C_1}{\partial P_1^{(i)}} = \frac{\partial}{\partial P_1^{(i)}} \left[-\frac{1}{m} \sum_{i=1}^m T_1^{(i)} \log(P_1^{(i)}) \right] = \boxed{-\frac{1}{m} \sum_{i=1}^m \frac{T_1^{(i)}}{P_1^{(i)}}} \quad (7)$$

y la primera derivada del $(S-1)$ -esimo termino: $\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \frac{\partial C_{S-1}}{\partial P_{S-1}^{(i)}} \dots$ es:

$$\frac{\partial C_{S-1}}{\partial P_{S-1}^{(i)}} = \frac{\partial}{\partial P_{S-1}^{(i)}} \left[-\frac{1}{m} \sum_{i=1}^m T_{S-1}^{(i)} \log(P_{S-1}^{(i)}) \right] = \boxed{-\frac{1}{m} \sum_{i=1}^m \frac{T_{S-1}^{(i)}}{P_{S-1}^{(i)}}} \quad (8)$$

Enseguida se muestra el procesamiento para resolver las derivadas de la función softmax. Esto corresponde a las derivadas de las predicciones $P_0^{(i)}, P_1^{(i)}, \dots, P_{S-1}^{(i)}$ con respecto a $z_0^{(i)}$ puesto que por ahora solo se desea conocer la derivada de la función de costo con respecto a $\omega_{2,0}$. Entonces, la primera derivada de la función softmax es:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \dots \frac{\partial P_0^{(i)}}{\partial z_0^{(i)}} \dots \text{ resolviéndose como:}$$

$$\frac{\partial P_0^{(i)}}{\partial z_0^{(i)}} = \frac{\partial}{\partial z_0^{(i)}} \left[\frac{e^{z_0^{(i)}}}{\sum_{d=0}^{S-1} e^{z_d^{(i)}}} \right] \quad (9)$$

$$= \frac{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right] \frac{\partial}{\partial z_0^{(i)}} e^{z_0^{(i)}} - e^{z_0^{(i)}} \frac{\partial}{\partial z_0^{(i)}} \left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]^2} \quad (10)$$

$$= \frac{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right] e^{z_0^{(i)}} - e^{z_0^{(i)}} e^{z_0^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]^2} = \frac{e^{z_0^{(i)}} \left(\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right] - e^{z_0^{(i)}} \right)}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]^2} \quad (11)$$

$$= \frac{e^{z_0^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]} \cdot \frac{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right] - e^{z_0^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]} = \boxed{P_0^{(i)}(1 - P_0^{(i)})} \quad (12)$$

$\underbrace{\quad\quad\quad}_{P_0^{(i)}} \uparrow$

Ahora, para la derivada de la función softmax del segundo termino: $\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \dots \frac{\partial P_1^{(i)}}{\partial z_0^{(i)}} \dots$ se tiene que:

$$\frac{\partial P_1^{(i)}}{\partial z_0^{(i)}} = \frac{\partial}{\partial z_0^{(i)}} \left[\frac{e^{z_1^{(i)}}}{\sum_{d=0}^{S-1} e^{z_d^{(i)}}} \right] \quad (13)$$

$$= \frac{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right] \frac{\partial}{\partial z_0^{(i)}} e^{z_1^{(i)}} - e^{z_1^{(i)}} \frac{\partial}{\partial z_0^{(i)}} \left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]^2} \quad (14)$$

$$= \frac{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right] (0) - e^{z_1^{(i)}} e^{z_0^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]^2} \quad (15)$$

$$= \frac{-e^{z_1^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]} \cdot \frac{e^{z_0^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]} = \boxed{-P_1^{(i)} P_0^{(i)}} \quad (16)$$

$\underbrace{\quad\quad\quad}_{-P_1^{(i)}} \uparrow \quad \quad \quad \underbrace{\quad\quad\quad}_{P_0^{(i)}} \uparrow$

siguiendo este proceso hasta la $(S-1)$ -ésima derivada de la función softmax: $\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \dots \frac{\partial P_{S-1}^{(i)}}{\partial z_0^{(i)}} \dots$ resulta:

$$\frac{\partial P_{S-1}^{(i)}}{\partial z_0^{(i)}} = \frac{\partial}{\partial z_0^{(i)}} \left[\frac{e^{z_{S-1}^{(i)}}}{\sum_{d=0}^{S-1} e^{z_d^{(i)}}} \right] \quad (17)$$

$$= \frac{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right] \frac{\partial}{\partial z_0^{(i)}} e^{z_{S-1}^{(i)}} - e^{z_{S-1}^{(i)}} \frac{\partial}{\partial z_0^{(i)}} \left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]^2} \quad (18)$$

$$= \frac{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right] (0) - e^{z_{S-1}^{(i)}} e^{z_0^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]^2} \quad (19)$$

$$= \frac{-e^{z_{S-1}^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]} \cdot \frac{e^{z_0^{(i)}}}{\left[\sum_{d=0}^{S-1} e^{z_d^{(i)}} \right]} = \boxed{-P_{S-1}^{(i)} P_0^{(i)}} \quad (20)$$

$\begin{array}{cc} \uparrow & \uparrow \\ -P_{S-1}^{(i)} & P_0^{(i)} \end{array}$

Nótese como los resultados de la función softmax $\frac{\partial P_a^{(i)}}{\partial z_b^{(i)}}$ tienen la misma forma $(-P_a^{(i)} P_b^{(i)})$ si $a \neq b$. En cambio, cuando $a = b$, es el caso cuando la forma del resultado es $P_a^{(i)}(1 - P_a^{(i)})$.

Finalmente, se resuelve una derivada que es común en todos los términos de la [Ecuación 5](#): $\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \dots \frac{\partial z_0^{(i)}}{\partial \omega_{2,0}} \dots$ resultando:

$$\begin{aligned} \frac{\partial z_0^{(i)}}{\partial \omega_{2,0}} &= \omega_{0,0} x_0^{(i)} + \omega_{1,0} x_1^{(i)} + \omega_{2,0} x_2^{(i)} + \dots + \omega_{n,0} x_n^{(i)} \\ &= \boxed{x_2^{(i)}} \end{aligned} \quad (21)$$

El resto del procedimiento es sustituir todos estos resultados en la [Ecuación 5](#):

$$\begin{aligned} \frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} &= \frac{\partial C_0}{\partial P_0^{(i)}} \frac{\partial P_0^{(i)}}{\partial z_0^{(i)}} \frac{\partial z_0^{(i)}}{\partial \omega_{2,0}} + \frac{\partial C_1}{\partial P_1^{(i)}} \frac{\partial P_1^{(i)}}{\partial z_0^{(i)}} \frac{\partial z_0^{(i)}}{\partial \omega_{2,0}} + \dots + \frac{\partial C_{S-1}}{\partial P_{S-1}^{(i)}} \frac{\partial P_{S-1}^{(i)}}{\partial z_0^{(i)}} \frac{\partial z_0^{(i)}}{\partial \omega_{2,0}} \end{aligned} \quad (22)$$

$\begin{array}{ccccccc} \uparrow & \uparrow & \uparrow & \uparrow & \uparrow & \uparrow & \uparrow \\ -\frac{1}{m} \sum_{i=1}^m \frac{T_0^{(i)}}{P_0^{(i)}} & \frac{x_2^{(i)}}{-\frac{1}{m} \sum_{i=1}^m \frac{T_1^{(i)}}{P_1^{(i)}}} & \frac{x_2^{(i)}}{-\frac{1}{m} \sum_{i=1}^m \frac{T_{S-1}^{(i)}}{P_{S-1}^{(i)}}} & \frac{x_2^{(i)}}{-P_1^{(i)} P_0^{(i)}} & \frac{x_2^{(i)}}{-P_{S-1}^{(i)} P_0^{(i)}} & \frac{x_2^{(i)}}{P_0^{(i)}(1 - P_0^{(i)})} & \frac{x_2^{(i)}}{P_0^{(i)}(1 - P_0^{(i)})} \end{array}$

Obteniendo:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = \left(-\frac{1}{m} \sum_{i=1}^m \frac{T_0^{(i)}}{P_0^{(i)}} \right) (P_0^{(i)}(1 - P_0^{(i)}))(x_2^{(i)}) + \left(-\frac{1}{m} \sum_{i=1}^m \frac{T_1^{(i)}}{P_1^{(i)}} \right) (-P_1^{(i)}P_0^{(i)})(x_2^{(i)}) + \dots \quad (23)$$

$$+ \left(-\frac{1}{m} \sum_{i=1}^m \frac{T_{S-1}^{(i)}}{P_{S-1}^{(i)}} \right) (-P_{S-1}^{(i)}P_0^{(i)})(x_2^{(i)}) \quad (24)$$

$$= -\frac{1}{m} \sum_{i=1}^m \frac{T_0^{(i)}}{P_0^{(i)}} P_0^{(i)}(1 - P_0^{(i)})x_2^{(i)} + \frac{1}{m} \sum_{i=1}^m \frac{T_1^{(i)}}{P_1^{(i)}} P_1^{(i)}P_0^{(i)}x_2^{(i)} + \dots + \frac{1}{m} \sum_{i=1}^m \frac{T_{S-1}^{(i)}}{P_{S-1}^{(i)}} P_{S-1}^{(i)}P_0^{(i)}x_2^{(i)} \quad (25)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left[T_0^{(i)}(1 - P_0^{(i)})x_2^{(i)} - T_1^{(i)}P_0^{(i)}x_2^{(i)} - \dots - T_{S-1}^{(i)}P_0^{(i)}x_2^{(i)} \right] \quad (26)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left[T_0^{(i)}x_2^{(i)} - T_0^{(i)}P_0^{(i)}x_2^{(i)} - T_1^{(i)}P_0^{(i)}x_2^{(i)} - \dots - T_{S-1}^{(i)}P_0^{(i)}x_2^{(i)} \right] \quad (27)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left[T_0^{(i)}x_2^{(i)} - (T_0^{(i)} + T_1^{(i)} + \dots + T_{S-1}^{(i)})P_0^{(i)}x_2^{(i)} \right] \quad (28)$$

$$(29)$$

En este punto se tiene como parte de la ecuación la sumatoria de los objetivos $(T_0^{(i)} + T_1^{(i)} + \dots + T_{S-1}^{(i)})$ lo cual es igual a uno, es debido que para cada muestra solo uno de los objetivos es “1” mientras que el resto es “0”. Entonces, la derivada se puede simplificar para obtener finalmente la expresión:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,0}} = -\frac{1}{m} \sum_{i=1}^m \left[T_0^{(i)}x_2^{(i)} - P_0^{(i)}x_2^{(i)} \right] = -\frac{1}{m} \sum_{i=1}^m (T_0^{(i)} - P_0^{(i)})x_2^{(i)} \quad (30)$$

$$= \boxed{\frac{1}{m} \sum_{i=1}^m (P_0^{(i)} - T_0^{(i)})x_2^{(i)}} \quad (31)$$

Este proceso puede repetirse para cada uno de los diferentes coeficientes. Sin embargo, es posible deducir el resultado que la derivada. Por ejemplo si ahora se desea obtener la derivada de la función de costo con respecto a $\omega_{3,0}$, el resultado sería:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{3,0}} = \frac{1}{m} \sum_{i=1}^m (P_0^{(i)} - T_0^{(i)})x_3^{(i)} \quad (32)$$

Por tanto la derivada de la función de costo con respecto a $\omega_{j,0}$ es:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{j,0}} = \frac{1}{m} \sum_{i=1}^m (P_0^{(i)} - T_0^{(i)})x_j^{(i)} \quad (33)$$

La misma lógica puede aplicarse, para deducir la derivada con respecto a $\omega_{2,1}$ por ejemplo, lo cual resultaría como:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{2,1}} = \frac{1}{m} \sum_{i=1}^m (P_1^{(i)} - T_1^{(i)})x_2^{(i)} \quad (34)$$

Consecuentemente la derivada de la función de costo para cualquier coeficiente $\omega_{j,k}$ es:

$$\frac{\partial C(\mathbf{P}, \mathbf{T})}{\partial \omega_{j,k}} = \frac{1}{m} \sum_{i=1}^m (P_k^{(i)} - T_k^{(i)}) x_j^{(i)} \quad (35)$$

A partir de la función de costo, sus derivadas se puede implementar el algoritmo de optimización. Considerando el algoritmo de gradiente descendente, un valor de $\alpha = 0.5$ y 1000 iteraciones se logran los resultados de la Figura 4 y Figura 5. Para obtener los resultados de Figura 4, se empleo un polinomio de grado 2 como función $f(\mathbf{x}^{(i)})$, es decir:

$$f(\mathbf{x}^{(i)}) = z_k^{(i)} = \omega_0 x_0^{(i)} + \omega_1 x_1^{(i)} + \omega_2 x_2^{(i)} + \omega_3 (x_1^{(i)})^2 + \omega_4 (x_2^{(i)})^2 \quad (36)$$

De esta manera se obtiene una precisión de 87.6% que aunque pareciera ser un resultado relativamente bueno es evidente que la frontera de decisión no sigue de manera adecuada la distribución de las muestras. En este sentido es necesario una hipótesis mas compleja.




Figura 4: Mapas de probabilidades (MP) para una hipótesis basada en polinomios de grado dos a) MP para la clase A b) MP para la clase B c) Frontera de decisión d) Costo obtenido por cada iteración del algoritmo GD.

En la [Figura 5](#) se muestra los resultados de clasificación usando una hipótesis basada en un polinomio de grado 3:

$$f(\mathbf{x}^{(i)}) = z_k^{(i)} = \omega_0 x_0^{(i)} + \omega_1 x_1^{(i)} + \omega_2 x_2^{(i)} + \omega_3 (x_1^{(i)})^2 + \omega_4 (x_2^{(i)})^2 + \omega_5 (x_1^{(i)})^3 + \omega_6 (x_2^{(i)})^3 \quad (37)$$

Así, es ahora posible lograr una precisión de 99.1% que ademas de ser superior que el resultado anterior, se tiene una frontera de decisión que sigue de manera fiel la distribución de las muestras.




Figura 5: Mapas de probabilidades (MP) para una hipótesis basada en polinomios de grado tres a) MP para la clase A b) MP para la clase B c) Frontera de decisión d) Costo obtenido por cada iteración del algoritmo GD.

Ejercicios

1. Replicar el ejercicio y los resultados mostrados en este documento