

Tema 9: Redes neuronales (Activación softmax)

EN este apartado se describirá el proceso para realizar una clasificación multiclase sobre los datos de la [Figura 1](#) empleando una RNA. El proceso es el mismo que el seguido en ejemplos anteriores, sin embargo se incorporará a la RNA la función de activación softmax en la capa de salida, mientras que las neuronas de la capa oculta conservan la función de activación sigmoide.




Figura 1: Muestras tomadas como referencia para describir un problema de clasificación multiclase usando una RNA.

En la [Figura 2](#) se ilustra la representación de la RNA tomada como referencia para describir el problema de clasificación. Dado que se emplea la función softmax en la capa de salida y se obtienen S_3 predicciones, es posible calcular S_3 costos $C_{k_2} \forall k_2 \in [1, S_3]$ mediante la entropía cruzada multiclase.




Figura 2: Representación de una RNA de tres capas. Se utiliza la función de activación softmax en la capa de salida.

Igual que en otros ejemplos, se requiere solo una función de costo que permita encontrar los pesos de la RNA tal que sea posible clasificar correctamente las muestras de la [Figura 1](#). En este sentido se continua utilizando como función de costo general la sumatoria de los costos por predicción:

$$C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)}) = C_1 + C_2 + \dots + C_{S_L} = -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_L} (T_d^{(i)} \log P_d^{(i)}) \quad (1)$$

A continuación, es necesario obtener la derivada de esta expresión con respecto a cada uno de los pesos ω . Se ilustra primeramente el proceso para obtener la derivada con respecto a los pesos de la capa dos. Sin embargo, por propósito de hacer mas amigable el entendimiento del calculo, se toma como base solo uno de estos pesos, en este caso $\omega_{2,1}$.




Figura 3: Representación de la contribución del peso $\omega_{2,1}^{(2)}$ hacia los costos por predicción.

En la Figura 3 se muestra la contribución de este pesos al costo total $C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})$ y dado que este costo total es la sumatoria $C_1 + C_2 + \dots + C_{S_L}$ es posible derivar individualmente cada costo por predicción con respecto al peso $\omega_{2,1}$:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{2,1}^{(2)}} = \frac{\partial C_1}{\partial \omega_{2,1}^{(2)}} + \frac{\partial C_2}{\partial \omega_{2,1}^{(2)}} + \dots + \frac{\partial C_{S_L}}{\partial \omega_{2,1}^{(2)}} \quad (2)$$

Empleando la regla de la cadena se descompone cada derivada en derivadas mas simples. Nótese que esta descomposición debe realizarse respetando la contribución del peso hacia cada uno de los costos por predicción, es decir:

$$\begin{aligned} \frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{2,1}^{(2)}} = & -\frac{1}{m} \sum_{i=1}^m \left(T_1^{(i)} \frac{\partial \log P_1^{(i)}}{\partial P_1^{(i)}} \frac{\partial P_1^{(i)}}{\partial z_1^{(3,i)}} \frac{\partial z_1^{(3,i)}}{\partial \omega_{2,1}^{(2)}} + T_2^{(i)} \frac{\partial \log P_2^{(i)}}{\partial P_2^{(i)}} \frac{\partial P_2^{(i)}}{\partial z_1^{(3,i)}} \frac{\partial z_1^{(3,i)}}{\partial \omega_{2,1}^{(2)}} + \dots + \right. \\ & \left. T_{S_3}^{(i)} \frac{\partial \log P_{S_3}^{(i)}}{\partial P_{S_3}^{(i)}} \frac{\partial P_{S_3}^{(i)}}{\partial z_1^{(3,i)}} \frac{\partial z_1^{(3,i)}}{\partial \omega_{2,1}^{(2)}} \right) \end{aligned} \quad (3)$$

Tomando la letra d como indicador de la d -esima predicción, se tiene el resultado de la primera derivada en cada termino como:

$$\frac{\partial \log P_d^{(i)}}{\partial P_d^{(i)}} = \boxed{\frac{1}{P_d^{(i)}}} \quad (4)$$

Asimismo, la derivada $\frac{\partial P_d^{(i)}}{\partial z_1^{(3,i)}}$ corresponde a la derivada de la función softmax. Así, cuando $d = 1$ se tiene:

$$\frac{\partial P_1^{(i)}}{\partial z_1^{(3,i)}} = \boxed{P_1^{(i)}(1 - P_1^{(i)})} \quad \forall \quad d = 1 \quad (5)$$

Por otro lado, cuando $d \neq 1$:

$$\frac{\partial P_d^{(i)}}{\partial z_1^{(3,i)}} = \boxed{-P_d^{(i)} P_1^{(i)}} \quad \forall \quad d \neq 1 \quad (6)$$

Por ultimo, el resultado de la ultima derivada a resolver queda como:

$$\frac{\partial z_1^{(3,i)}}{\partial \omega_{2,1}^{(2)}} = \frac{\partial}{\partial \omega_{2,1}^{(2)}} \sum_{h=0}^{S_2} \omega_{h,1}^{(2)} a_h^{(2,i)} \quad (7)$$

$$= \frac{\partial}{\partial \omega_{2,1}^{(2)}} \omega_{0,1}^{(2)} a_0^{(2,i)} + \omega_{1,1}^{(2)} a_1^{(2,i)} + \dots + \omega_{S_2,1}^{(2)} a_{S_2}^{(2,i)} = a_2^{(2,i)} \quad (8)$$

Sustituyendo los resultados se tiene la expresión final:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{2,1}^{(2)}} = -\frac{1}{m} \sum_{i=1}^m \left(T_1^{(i)} \frac{1}{P_1^{(i)}} P_1^{(i)} (1 - P_1^{(i)}) a_2^{(2,i)} + T_2^{(i)} \frac{1}{P_2^{(i)}} (-P_2^{(i)} P_1^{(i)}) a_2^{(2,i)} + \dots + \right. \quad (9)$$

$$\left. T_{S_3}^{(i)} \frac{1}{P_{S_3}^{(i)}} (-P_{S_3}^{(i)} P_1^{(i)}) a_2^{(2,i)} \right) \\ = -\frac{1}{m} \sum_{i=1}^m \left((T_1^{(i)} - T_1^{(i)} P_1^{(i)}) a_2^{(2,i)} - T_2^{(i)} P_1^{(i)} a_2^{(2,i)} - \dots - T_{S_3}^{(i)} P_1^{(i)} a_2^{(2,i)} \right) \quad (10)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left(T_1^{(i)} - (T_1^{(i)} + T_2^{(i)} + \dots + T_{S_3}^{(i)}) P_1^{(i)} \right) a_2^{(2,i)} \quad (11)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left(T_1^{(i)} - P_1^{(i)} \right) a_2^{(2,i)} = \boxed{\frac{1}{m} \sum_{i=1}^m \left(P_1^{(i)} - T_1^{(i)} \right) a_2^{(2,i)}} \quad (12)$$

Es posible repetir este procedimiento para los diferentes pesos de la capa dos. Sin embargo de forma intuitiva se puede deducir la expresión resultante para cada peso en esta misma capa. Entonces se puede establecer su forma general como:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_2, k_2}^{(2)}} = \boxed{\frac{1}{m} \sum_{i=1}^m (P_{k_2}^{(i)} - T_{k_2}^{(i)}) a_{j_2}^{(2,i)}} \quad (13)$$

Ahora, para obtener la derivada de la función de costo total $C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})$ con respecto a los pesos de la capa uno, se ilustra el procedimiento de igual forma tomando solo un peso como referencia. En la [Figura 4](#) se ilustra la manera en que contribuye el peso arbitrariamente seleccionado $\omega_{1,2}^{(1)}$ a $C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})$. Nuevamente, es necesario derivar cada uno de los términos en la sumatoria de la función de costo:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{1,2}^{(1)}} = \frac{\partial C_1}{\partial \omega_{1,2}^{(1)}} + \frac{\partial C_2}{\partial \omega_{1,2}^{(1)}} + \dots + \frac{\partial C_{S_L}}{\partial \omega_{1,2}^{(1)}} \quad (14)$$

Empleando la regla de la cadena para descomponer cada derivada es derivadas mas sencillas y respetando la contribución del peso $\omega_{1,2}^{(1)}$ al costo total, se tiene:




Figura 4: Representación de la contribución del peso $\omega_{1,2}^{(1)}$ hacia los costos por predicción.

$$\begin{aligned}
 \frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{1,2}^{(1)}} = & -\frac{1}{m} \sum_{i=1}^m \left(T_1^{(i)} \frac{\partial \log P_1^{(i)}}{\partial P_1^{(i)}} \frac{\partial P_1^{(i)}}{\partial z_d^{(3,i)}} \frac{\partial z_d^{(3,i)}}{\partial a_2^{(2,i)}} \frac{\partial a_2^{(2,i)}}{\partial z_2^{(2,i)}} \frac{\partial z_2^{(2,i)}}{\partial \omega_{1,2}^{(1)}} \right. \\
 & T_2^{(i)} \frac{\partial \log P_2^{(i)}}{\partial P_2^{(i)}} \frac{\partial P_2^{(i)}}{\partial z_d^{(3,i)}} \frac{\partial z_d^{(3,i)}}{\partial a_2^{(2,i)}} \frac{\partial a_2^{(2,i)}}{\partial z_2^{(2,i)}} \frac{\partial z_2^{(2,i)}}{\partial \omega_{1,2}^{(1)}} + \dots + \\
 & \left. T_{S_3}^{(i)} \frac{\partial \log P_{S_3}^{(i)}}{\partial P_{S_3}^{(i)}} \frac{\partial P_{S_3}^{(i)}}{\partial z_d^{(3,i)}} \frac{\partial z_d^{(3,i)}}{\partial a_2^{(2,i)}} \frac{\partial a_2^{(2,i)}}{\partial z_2^{(2,i)}} \frac{\partial z_2^{(2,i)}}{\partial \omega_{1,2}^{(1)}} \right) \quad (15)
 \end{aligned}$$

Aquí, se tiene la derivada $\frac{\partial \log P_d^{(i)}}{\partial P_d^{(i)}}$ que tiene su solución en la [Ecuación 4](#). Dado que el peso $\omega_{1,2}^{(1)}$ contribuye a todas las variables z de la capa tres, así como a todas las predicciones, las derivadas $\frac{\partial P_1^{(i)}}{\partial z_d^{(3,i)}}, \frac{\partial P_2^{(i)}}{\partial z_d^{(3,i)}}, \dots, \frac{\partial P_{S_3}^{(i)}}{\partial z_d^{(3,i)}}$ implican que cada derivada de $P_{k_2}^{(i)}$ tiene que realizarse S_3 veces; una vez con respecto a cada variable $z^{(3)}$. Entonces: sus derivadas son:

$$\frac{\partial P_{k_2}^{(i)}}{\partial z_d^{(3,i)}} = \boxed{P_{k_2}^{(i)}(1 - P_{k_2}^{(i)})} \quad \forall \quad k_2 = d \quad (16)$$

y

$$\frac{\partial P_{k_2}^{(i)}}{\partial z_d^{(3,i)}} = \boxed{-P_{k_2}^{(i)} P_d^{(i)}} \quad \forall \quad k_2 \neq d \quad (17)$$

Luego, la derivada $\frac{\partial z_d^{(3,i)}}{\partial a_2^{(2,i)}}$ resulta:

$$\frac{\partial z_d^{(3,i)}}{\partial a_2^{(2,i)}} = \frac{\partial}{\partial a_2^{(2,i)}} \sum_{h=0}^{S_2} \omega_{h,d}^{(2)} a_h^{(2,i)} \quad (18)$$

$$= \frac{\partial}{\partial a_2^{(2,i)}} \omega_{0,d}^{(2)} a_0^{(2,i)} + \omega_{1,d}^{(2)} a_1^{(2,i)} + \dots + \omega_{S_2,d}^{(2)} a_{S_2}^{(2,i)} = \boxed{\omega_{2,d}^{(2)}} \quad (19)$$

La derivada $\frac{\partial a_2^{(2,i)}}{\partial z_2^{(2,i)}}$ es la derivada de la función sigmoide, resultando:

$$\frac{\partial a_2^{(2,i)}}{\partial z_2^{(2,i)}} = \boxed{a_2^{(2,i)}(1 - a_2^{(2,i)})} \quad (20)$$

Finalmente, la ultima derivada simple es:

$$\frac{\partial z_2^{(2,i)}}{\partial \omega_{1,2}^{(1)}} = \frac{\partial}{\partial \omega_{1,2}^{(1)}} \sum_{h=0}^n \omega_{h,2}^{(1)} x_h^{(i)} \quad (21)$$

$$= \frac{\partial}{\partial \omega_{1,2}^{(1)}} \omega_{0,2}^{(1)} x_0^{(i)} + \omega_{1,2}^{(1)} x_1^{(i)} + \dots + \omega_{n,2}^{(1)} x_n^{(i)} = \boxed{x_1^{(i)}} \quad (22)$$

Sustituyendo los resultados y simplificando se obtiene:

$$\begin{aligned} \frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{1,2}^{(1)}} &= -\frac{1}{m} \sum_{i=1}^m \left(T_1^{(i)} \frac{1}{P_1^{(i)}} (P_1^{(i)}(1 - P_1^{(i)}) - P_1^{(i)} P_2^{(i)} - \dots - P_1^{(i)} P_{S_3}^{(i)}) \omega_{2,d}^{(2)} a_2^{(2,i)} (1 - a_2^{(2,i)}) x_1^{(i)} \right. \\ &\quad + T_2^{(i)} \frac{1}{P_2^{(i)}} (P_2^{(i)}(1 - P_2^{(i)}) - P_2^{(i)} P_1^{(i)} - \dots - P_2^{(i)} P_{S_3}^{(i)}) \omega_{2,d}^{(2)} a_2^{(2,i)} (1 - a_2^{(2,i)}) x_1^{(i)} + \dots + \\ &\quad \left. T_{S_3}^{(i)} \frac{1}{P_{S_3}^{(i)}} (P_{S_3}^{(i)}(1 - P_{S_3}^{(i)}) - P_{S_3}^{(i)} P_1^{(i)} - \dots - P_{S_3}^{(i)} P_{S_3-1}^{(i)}) \omega_{2,d}^{(2)} a_2^{(2,i)} (1 - a_2^{(2,i)}) x_1^{(i)} \right) \end{aligned} \quad (23)$$

$$\begin{aligned} &= -\frac{1}{m} \sum_{i=1}^m \left(T_1^{(i)} ((1 - P_1^{(i)}) - P_2^{(i)} - \dots - P_{S_3}^{(i)}) \right. \\ &\quad + T_2^{(i)} ((1 - P_2^{(i)}) - P_1^{(i)} - \dots - P_{S_3}^{(i)}) + \dots + \\ &\quad \left. T_{S_3}^{(i)} ((1 - P_{S_3}^{(i)}) - P_1^{(i)} - \dots - P_{S_3-1}^{(i)}) \right) \omega_{2,d}^{(2)} a_2^{(2,i)} (1 - a_2^{(2,i)}) x_1^{(i)} \end{aligned} \quad (24)$$

$$\begin{aligned} &= -\frac{1}{m} \sum_{i=1}^m \left((T_1^{(i)} - T_1^{(i)} P_1^{(i)} - T_1^{(i)} P_2^{(i)} - \dots - T_1^{(i)} P_{S_3}^{(i)}) \right. \\ &\quad + (T_2^{(i)} - T_2^{(i)} P_2^{(i)} - T_2^{(i)} P_1^{(i)} - \dots - T_2^{(i)} P_{S_3}^{(i)}) + \dots + \\ &\quad \left. (T_{S_3}^{(i)} - T_{S_3}^{(i)} P_{S_3}^{(i)} - T_{S_3}^{(i)} P_1^{(i)} - \dots - T_{S_3}^{(i)} P_{S_3-1}^{(i)}) \right) \omega_{2,d}^{(2)} a_2^{(2,i)} (1 - a_2^{(2,i)}) x_1^{(i)} \end{aligned} \quad (25)$$

$$\begin{aligned} &= -\frac{1}{m} \sum_{i=1}^m \left((T_1^{(i)} - P_1^{(i)} (T_1^{(i)} + T_2 + \dots T_{S_3})) \right. \\ &\quad + (T_2^{(i)} - P_2^{(i)} (T_1^{(i)} + T_2 + \dots T_{S_3})) + \dots + \\ &\quad \left. (T_{S_3}^{(i)} - P_{S_3}^{(i)} (T_1^{(i)} + T_2 + \dots T_{S_3})) \right) \omega_{2,d}^{(2)} a_2^{(2,i)} (1 - a_2^{(2,i)}) x_1^{(i)} \end{aligned} \quad (26)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left((T_1^{(i)} - P_1^{(i)} + T_2^{(i)} - P_2^{(i)} + \dots + T_{S_3}^{(i)} - P_{S_3}^{(i)}) \omega_{2,d}^{(2)} a_2^{(2,i)} (1 - a_2^{(2,i)}) x_1^{(i)} \right) \quad (27)$$

$$= \boxed{\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} (P_d^{(i)} - T_d^{(i)}) \omega_{2,d}^{(2)} a_2^{(2,i)} (1 - a_2^{(2,i)}) x_1^{(i)}} \quad (28)$$

Repitiendo este procedimiento para el resto de pesos de la capa uno es posible conocer el resto de derivadas, sin embargo, también es posible deducir la forma general de la expresión:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_1, k_1}^{(1)}} = -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} (T_d^{(i)} - P_d^{(i)}) \omega_{k_1, d}^{(2)} a_{k_1}^{(2, i)} (1 - a_{k_1}^{(2, i)}) x_{j_1}^{(i)} \quad (29)$$

A partir de estas expresiones encontradas, es posible implementar el algoritmo de optimización. Para este ejemplo se utiliza el algoritmo de gradiente descendente con momentum, el cual, sigue la siguiente regla de actualización individualmente para cada peso ω :

$$v_{t+1} = \gamma \times v_t + \alpha \frac{\partial C}{\partial \omega} \quad (30)$$

$$\omega_{t+1} = \omega_t - v_{t+1} \quad (31)$$

Se considera una RNA de 50 neuronas en la capa oculta, un valor $\alpha = 0.1$, $\gamma = 0.99$, 15000 iteraciones, pesos en ambas capas inicializados de forma aleatoria con distribución normal (media 0, desviación estandar 0.1) para así lograr los resultados de la Figura 5 y Figura 6. En estos resultados mostrados la precisión en la clasificación es de 100%. Cabe destacar que debido a que los pesos son inicializados de forma aleatoria, el punto de convergencia del algoritmo de optimización no siempre es el mismo, lo que implica que los frontera de decisión no sera siempre igual. Sin embargo, con los parámetros de entrenamiento mencionados la precisión siempre estará cercana al 100% ($> 97\%$).




Figura 5: Resultado del entrenamiento de la RNA con 50 neuronas en la capa oculta: a) MP para P_1 b) MP para P_2 c) MP para P_3 d) MP para P_4




Figura 6: Resultado del entrenamiento de la RNA con 50 neuronas en la capa oculta: a) Frontera de decisión b) Costo obtenido en cada iteraci3n del algoritmo de entrenamiento.

Ejercicios

1. Replicar el ejercicio y los resultados mostrados en este documento