

Tema 9: Redes neuronales (Completamente conectadas)

En este apartado se describirá el funcionamiento de un modelo de *Red Neuronal Artificial* (RNA). En temas anteriores se presentaron los temas de regresión lineal y regresión logística, donde a partir de un modelo matemático (hipótesis) basado en un polinomio es posible para un conjunto de muestras, describir su tendencia (Regresión) o asignar una clase (Clasificación). A diferencia de las herramientas mencionadas, típicamente en un modelos de RNA parten del *Modelo matemático simplificado de una neurona biológica* representado en la [Figura 1](#). Este modelo toma a su entrada $n + 1$ valores de entrada ($x_0 = 1$) para producir un resultado parcial z , que a su vez es procesado por una función de activación para generar un valor de *activación* a , matemáticamente:

$$a^{(i)} = g(z^{(i)}) = g(\omega_0 x_0 + \omega_1 x_1 + \dots + \omega_n x_n) \quad (1)$$




Figura 1: Modelo matemático simplificado de una neurona biológica.

donde la función $g(\cdot)$ es una función de activación no lineal, por ejemplo, la función sigmoide. Entonces una RNA es un arreglo de neuronas interconectadas entre sí. El tipo de RNA mas común es la *Red neuronal completamente conectada* que se ilustra en la [Figura 2](#). Ésta se encuentra organizada por capas (Capa de entrada, capa de salida y un número arbitrario de capas ocultas) y cada capa esta constituida por un conjunto de neuronas. La capa de entrada denota el conjunto de n valores de entrada a la red (también llamados *características*). Estos valores de entrada se consideran activaciones pero existe la excepción de que no fueron neuronas las que produjeron estos valores. Nótese que $x_0 = 1$ es un valor constante y se considera parte del modelo de la RNA mas no un valor de entrada. El número de neuronas en una capa (oculta o de salida) esta indicado por s_l siendo l el indice de la capa, por ejemplo, si $l = 1$ se señala a la capa de entrada, si $l = 2$ se señala a la capa 2 (capa oculta en la [Figura 2](#)) o si $l = 3$ se señala a la capa 3 (capa de salida en la [Figura 2](#)). Entonces, S_2 indica el número de neuronas en la capa 2 y S_3 el número de neuronas en la capa 3. Asimismo, L ($l \in [1, L]$) representa la cantidad total de capas, siendo $L = 3$ para la RNA tomada como referencia ([Figura 2](#)). Así, s_L indica el número de neuronas en la capa de salida.

Dado que los resultados de las sumatorias z así como las activaciones a , se utilizan subindices y superindices para diferenciarlos. Un superindice (l, i) se emplea para informar a que capa (l) y sobre que muestra (i) se produjo z o a . Un subindice k_l apunta a la k_l -esima neurona. Un escenario similar ocurre para los coeficientes ω (En el contexto de RNA, a estos coeficientes también se les suele llamar *pesos* o *parámetros*). Se utiliza un superindice (l) para establecer a que capa esta asociado el conjunto de pesos mientras que un subindice compuesto de dos valores j_l, k_l revelan la asociación del peso, es decir, de que activación (j_l) proviene la conexión y a que neurona va (k_l). En la [Figura 2](#), $j_1 \in [0, n]$, $k_1 \in [1, S_2]$, $j_2 \in [0, S_2]$ y $k_2 \in [1, S_3]$, por lo que $k_2 \equiv j_2$.

Finalmente, P es empleado para representar la predicción de la RNA. Dependiendo en número de neuronas en la capa de salida, será la cantidad de valores que constituyan la predicción. Para identificar individualmente cada valor de salida, se emplea un superindice (i) para aclarar sobre que muestra se produjo P (no es necesario indicar la capa puesto que la predicción siempre es el conjunto de valores de salida de la capa de salida). También, se emplea un subindice k_l para señalar la neurona.




Figura 2: Representación de una red neuronal artificial

Para obtener la predicción de la RNA es necesario obtener primero las activaciones de la capa 2, posteriormente las de la capa 3 y en caso de que hubiera más capas, este proceso se tiene que repetir hasta la última capa (capa de salida) realizando así el cálculo de las activaciones de izquierda a derecha de acuerdo con la Figura 2. A este proceso se le conoce como *propagación hacia adelante* o *inferencia* y se puede representar matemáticamente siguiendo las siguientes ecuaciones:

$$z_{k_1}^{(2,i)} = \sum_{j_1=0}^n \omega_{j_1,k_1}^{(1)} x_{j_1}^{(i)} = \omega_{0,k_1}^{(1)} x_0^{(i)} + \omega_{1,k_1}^{(1)} x_1^{(i)} + \dots + \omega_{n,k_1}^{(1)} x_n^{(i)} \quad (2)$$

$$a_{k_1}^{(2,i)} = g(z_{k_1}^{(2,i)}) \quad (3)$$

$$z_{k_2}^{(3,i)} = \sum_{j_2=0}^{S_2} \omega_{j_2,k_2}^{(2)} a_{j_2}^{(2,i)} = \omega_{0,k_2}^{(2)} a_0^{(2,i)} + \omega_{1,k_2}^{(2)} a_1^{(2,i)} + \dots + \omega_{S_2,k_2}^{(2)} a_{S_2}^{(2,i)} \quad (4)$$

$$P_{k_2} = a_{k_2}^{(3,i)} = g(z_{k_2}^{(3,i)}) \quad (5)$$

donde los valores de entrada a la RNA puede considerarse activaciones de la capa 1 tal que $x_{j_1}^{(i)} = a_{j_1}^{(1,i)}$ y $S_1 = n$ pudiendo así representar el cálculo de z y a de forma general:

$$z_{k_l}^{(l+1,i)} = \sum_{j_l=0}^{S_l} \omega_{j_l,k_l}^{(l)} a_{j_l}^{(l,i)} = \omega_{0,k_l}^{(l)} a_0^{(l,i)} + \omega_{1,k_l}^{(l)} a_1^{(l,i)} + \dots + \omega_{S_l,k_l}^{(l)} a_{S_l}^{(l,i)} \quad (6)$$

$$a_{k_l}^{(l,i)} = g(z_{k_l}^{(l,i)}) \quad (7)$$

También, es posible adoptar la notación vectorial teniendo que cada conjunto $\mathbf{z}^{(l,i)}$ y $\mathbf{a}^{(l,i)}$ representan vectores columna pudiendo adquirirse como:

$$\mathbf{z}^{(l+1,i)} = \begin{bmatrix} z_0^{(l+1,i)} \\ z_1^{(l+1,i)} \\ z_2^{(l+1,i)} \\ \vdots \\ z_{S_{l+1}}^{(l+1,i)} \end{bmatrix} = (\mathbf{a}^{(l,i)})^\top \cdot \mathbf{W}^{(l)} = \begin{bmatrix} a_0^{(l,i)} & a_1^{(l,i)} & a_2^{(l,i)} & \dots & a_{S_l}^{(l,i)} \end{bmatrix} \cdot \begin{bmatrix} \omega_{0,0}^{(l)} & \omega_{0,1}^{(l)} & \omega_{0,2}^{(l)} & \dots & \omega_{0,S_{l+1}}^{(l)} \\ \omega_{1,0}^{(l)} & \omega_{1,1}^{(l)} & \omega_{1,2}^{(l)} & \dots & \omega_{1,S_{l+1}}^{(l)} \\ \omega_{2,0}^{(l)} & \omega_{2,1}^{(l)} & \omega_{2,2}^{(l)} & \dots & \omega_{2,S_{l+1}}^{(l)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \omega_{S_l,0}^{(l)} & \omega_{S_l,1}^{(l)} & \omega_{S_l,2}^{(l)} & \dots & \omega_{S_l,S_{l+1}}^{(l)} \end{bmatrix} \quad (8)$$

$$\mathbf{a}^{(l,i)} = \begin{bmatrix} a_0^{(l,i)} \\ a_1^{(l,i)} \\ a_2^{(l,i)} \\ \vdots \\ a_{S_l}^{(l,i)} \end{bmatrix} = g(\mathbf{z}^{(l,i)}) = \begin{bmatrix} g(z_0^{(l,i)}) \\ g(z_1^{(l,i)}) \\ g(z_2^{(l,i)}) \\ \vdots \\ g(z_{S_l}^{(l,i)}) \end{bmatrix} \quad (9)$$

Una vez comprendida la operación de una RNA es posible emplearla para resolver un problema de regresión o clasificación. En este apartado se tomará como referencia un problema de clasificación considerado el conjunto de muestras ilustrado en la [Figura 3](#). Este conjunto está dividido en dos clases y la intención es encontrar los pesos tal que provoquen que todo el modelo de la RNA represente una frontera de decisión que separe las clases. En el contexto de redes neuronales este proceso para encontrar los parámetros que satisfagan nuestros propósitos (clasificar las muestras [Figura 3](#), en este caso) se le conoce como *Entrenamiento de la RNA* y tiene los mismo pasos que los ya descritos en temas de regresión lineal y regresión logística.




Figura 3: Conjunto de muestras dividido en dos clases tomado como ejemplo para ilustrar el proceso de entrenamiento de una RNA para una tarea de clasificación

1. **Proponer una hipótesis:** El modelo matemático de la RNA es la hipótesis. En este sentido, se tiene que definir lo que se conoce como *configuración de la RNA* o *arquitectura de la RNA*. Esta configuración está representada por los *hiperparámetros*: n , L , $S_{1,2}, \dots, S_L$ y $g(\cdot)$. Así, se define: 1) el número de capas ocultas, 2) la cantidad de neuronas en cada capa oculta, 3) la función de activación (Una práctica común es emplear el mismo tipo de función de activación para todas las neuronas). Notese que el número de activaciones en la capa de entrada está dado por el número de características n y el número de neuronas de salida depende del número de clases (En el caso de una tarea de clasificación). Para este ejemplo, los hiperparámetros quedan de la siguiente manera:

- $n = S_1 = 2$ (Dado por las dos características x_1 y x_2)
- $L = 3$ (Arbitrariamente se opta por solo emplear una capa oculta tal como se representa en la Figura 2)
- $S_2 = 10$ (10 es un número arbitrario puesto que no existe regla para definirlo)
- $S_L = S_3 = 2$ (Dado por las dos clases: Clase A y Clase B)
- $g(\cdot) = g(z) = \frac{1}{1 + e^{-z}}$ (Debido a que es un problema de clasificación la función sigmoide es adecuada)

2. **Inicializar los pesos:** En modelos de RNAs es requisito inicializar los pesos con valores aleatorios cercanos a ceros, la explicación de ésto se puede encontrar en el tema “Inicialización de los pesos”.
3. **Definir una función de costo:** En la Figura 4 se muestra que para cada predicción P_{k_2} se puede calcular un costo C_{k_2} (Se toma la entropía cruzada binaria para cuantificar el costo al igual que en una clasificación multiclase basada en regresión logística, esto es debido al uso de la función de activación sigmoide). Sin embargo, como ya antes se ha mencionado, un proceso de optimización parte de una única función a optimizar, por ello se considera como función de costo a optimizar aquella que representa la sumatoria de los costo individuales por predicción:




Figura 4: Representación de una red neuronal artificial

$$C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)}) = C_1 + C_2 + \dots + C_{S_L} \quad (10)$$

$$= -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_L} (T_d^{(i)} \log P_d^{(i)} + (1 - T_d^{(i)}) \log(1 - P_d^{(i)})) \quad (11)$$

4. **Obtener las derivadas de la función de costo:** Una vez definida la función de costo, es necesario obtener su derivada con respecto a cada uno de los pesos $\mathbf{W}^{(1)}$ y $\mathbf{W}^{(2)}$. Este proceso se realiza en el mismo estilo que la propagación hacia adelante. La diferencia en esta ocasión es que el calculo de las derivadas se realiza primero con respecto a los pesos de la capa $L - 1$, es decir, con respecto a los pesos de la capa dos ($\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j2,k2}^{(2)}}$) y posteriormente se realiza el calculo de la derivada de la función de costo con respecto a los pesos de la capa $L - 2$, es decir, la derivada con respecto a los pesos de la capa uno ($\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j1,k1}^{(1)}}$). Dado que este proceso se realiza de derecha a izquierda (al contrario de la propagación hacia adelante) se denota a éste como *propagación hacia atrás*, el cual se refiere al proceso de obtención de las derivadas de la función de costo con respecto a los pesos de las capas $L - 1, L - 2, \dots$, etc. Entonces la derivada con respecto a los pesos de la capa dos queda expresada como:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_2, k_2}^{(2)}} = \frac{\partial C_1}{\partial \omega_{j_2, k_2}^{(2)}} + \frac{\partial C_2}{\partial \omega_{j_2, k_2}^{(2)}} + \dots + \frac{\partial C_{S_3}}{\partial \omega_{j_2, k_2}^{(2)}} \quad (12)$$

y la derivada de la función de costo con respecto a los pesos de la capa uno es:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_1, k_1}^{(1)}} = \frac{\partial C_1}{\partial \omega_{j_1, k_1}^{(1)}} + \frac{\partial C_2}{\partial \omega_{j_1, k_1}^{(1)}} + \dots + \frac{\partial C_{S_3}}{\partial \omega_{j_1, k_1}^{(1)}} \quad (13)$$

Comenzado a resolver para los pesos de la capa dos ($\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_2, k_2}^{(2)}}$) tenemos una descomposición de términos empleando la regla de la cadena:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_2, k_2}^{(2)}} = -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} \frac{\partial \log P_d^{(i)}}{\partial P_d^{(i)}} \frac{\partial P_d^{(i)}}{\partial z_d^{(3,i)}} \frac{\partial z_d^{(3,i)}}{\partial \omega_{j_2, k_2}^{(2)}} + (1 - T_d^{(i)}) \frac{\partial \log(1 - P_d^{(i)})}{\partial P_d^{(i)}} \frac{\partial P_d^{(i)}}{\partial z_d^{(3,i)}} \frac{\partial z_d^{(3,i)}}{\partial \omega_{j_2, k_2}^{(2)}} \right) \quad (14)$$

Así, el resultado de la primera derivada en el primer termino es:

$$\frac{\partial \log P_d^{(i)}}{\partial P_d^{(i)}} = \boxed{\frac{1}{P_d^{(i)}}} \quad (15)$$

De igual manera, el resultado de la primera derivada para el segundo termino resulta:

$$\frac{\partial \log(1 - P_d^{(i)})}{\partial P_d^{(i)}} = \boxed{\frac{-1}{1 - P_d^{(i)}}} \quad (16)$$

La derivada $\frac{\partial P_d^{(i)}}{\partial z_d^{(3,i)}}$ es la derivada de la función de activación. Debido a que se esta resolviendo un problema de clasificación se seleccionó la función sigmoide, siendo su derivada:

$$\frac{\partial P_d^{(i)}}{\partial z_d^{(3,i)}} = \boxed{P_d^{(i)}(1 - P_d^{(i)})} \quad (17)$$

Por ultimo, el resultado de la ultima derivada a resolver queda de la siguiente manera:

$$\frac{\partial z_d^{(3,i)}}{\partial \omega_{j_2, k_2}^{(2)}} = \frac{\partial}{\partial \omega_{j_2, k_2}^{(2)}} \sum_{h=0}^{S_2} \omega_{h, d}^{(2)} a_h^{(2,i)} \quad (18)$$

$$= \frac{\partial}{\partial \omega_{j_2, k_2}^{(2)}} \omega_{0, d}^{(2)} a_0^{(2,i)} + \omega_{1, d}^{(2)} a_1^{(2,i)} + \dots + \omega_{S_2, d}^{(2)} a_{S_2}^{(2,i)} = \varphi_{j_2}^{(2,i)} = \begin{cases} \boxed{a_{j_2}^{(2,i)}} & \text{si } d = k_2 \\ 0 & \text{si } d \neq k_2. \end{cases} \quad (19)$$

Sustituyendo los resultados y simplificando se tiene la expresión final:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_2, k_2}^{(2)}} = -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} \frac{1}{P_d^{(i)}} P_d^{(i)} (1 - P_d^{(i)}) \varphi_{j_2}^{(2,i)} + (1 - T_d^{(i)}) \left(\frac{-1}{1 - P_d^{(i)}} \right) P_d^{(i)} (1 - P_d^{(i)}) \varphi_{j_2}^{(2,i)} \right) \quad (20)$$

$$= -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} (1 - P_d^{(i)}) \varphi_{j_2}^{(2,i)} - (1 - T_d^{(i)}) P_d^{(i)} \varphi_{j_2}^{(2,i)} \right) \quad (21)$$

$$= -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} \varphi_{j_2}^{(2,i)} - T_d^{(i)} P_d^{(i)} \varphi_{j_2}^{(2,i)} - P_d^{(i)} \varphi_{j_2}^{(2,i)} + T_d^{(i)} P_d^{(i)} \varphi_{j_2}^{(2,i)} \right) \quad (22)$$

$$= -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} \varphi_{j_2}^{(2,i)} - P_d^{(i)} \varphi_{j_2}^{(2,i)} \right) \quad (23)$$

$$= \frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} (P_d^{(i)} - T_d^{(i)}) \varphi_{j_2}^{(2,i)} \quad (24)$$

Opcionalmente, se puede expresar la derivada en términos de $a_{j_2}^{(2,i)}$ teniendo:

$$\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_2, k_2}^{(2)}} = \boxed{\frac{1}{m} \sum_{i=1}^m (P_{k_2}^{(i)} - T_{k_2}^{(i)}) a_{j_2}^{(2,i)}} \quad (25)$$

Continuando con la derivada de la función de costo con respecto a los pesos de la capa uno ([Ecuación 13](#)), se tiene la descomposición en derivadas mas simples empleando la regla de cadena:

$$\begin{aligned} \frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_1, k_1}^{(1)}} = & -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} \frac{\partial \log P_d^{(i)}}{\partial P_d^{(i)}} \frac{\partial P_d^{(i)}}{\partial z_d^{(3,i)}} \frac{\partial z_d^{(3,i)}}{\partial a_b^{(2,i)}} \frac{\partial a_b^{(2,i)}}{\partial z_b^{(2,i)}} \frac{\partial z_b^{(2,i)}}{\partial \omega_{j_1, k_1}^{(1)}} \right. \\ & \left. + (1 - T_d^{(i)}) \frac{\partial \log(1 - P_d^{(i)})}{\partial P_d^{(i)}} \frac{\partial P_d^{(i)}}{\partial z_d^{(3,i)}} \frac{\partial z_d^{(3,i)}}{\partial a_b^{(2,i)}} \frac{\partial a_b^{(2,i)}}{\partial z_b^{(2,i)}} \frac{\partial z_b^{(2,i)}}{\partial \omega_{j_1, k_1}^{(1)}} \right) \end{aligned} \quad (26)$$

Donde $b \equiv k_1$.

Nótese que existen derivadas ya resueltas y la descomposición en derivadas mas simples tiene que realizarse hasta lograr derivar la función que directamente depende de $\omega_{j_1, k_1}^{(1)}$. Entonces, derivando cada una de las expresiones mas simples se tiene:

$$\frac{\partial z_d^{(3,i)}}{\partial a_b^{(2,i)}} = \frac{\partial}{\partial a_b^{(2,i)}} \sum_{h=0}^{S_2} \omega_{h,d}^{(2)} a_h^{(2,i)} = \frac{\partial}{\partial a_b^{(2,i)}} \omega_{0,d}^{(2)} a_0^{(2,i)} + \omega_{1,d}^{(2)} a_1^{(2,i)} + \dots + \omega_{S_2,d}^{(2)} a_{S_2}^{(2,i)} = \boxed{\omega_{b,d}^{(2)}} \quad (27)$$

mientras que $\frac{\partial a_b^{(2,i)}}{\partial z_b^{(2,i)}}$ resulta nuevamente ser la derivada de la función sigmoide:

$$\frac{\partial a_b^{(2,i)}}{\partial z_b^{(2,i)}} = \boxed{a_b^{(2,i)} (1 - a_b^{(2,i)})} \quad (28)$$

y la ultima derivada es:

$$\frac{\partial z_b^{(2,i)}}{\partial \omega_{j_1,k_1}^{(1)}} = -\frac{\partial}{\partial \omega_{j_1,k_1}^{(1)}} \sum_{h=0}^n \omega_{h,b}^{(1)} x_h^{(i)} \quad (29)$$

$$= -\frac{\partial}{\partial \omega_{j_1,k_1}^{(1)}} \omega_{0,b}^{(1)} x_0^{(i)} + \omega_{1,b}^{(1)} x_1^{(i)} + \dots + \omega_{n,b}^{(1)} x_n^{(i)} = \varphi_{j_1}^{(1,i)} = \begin{cases} \boxed{x_{j_1}^{(i)}} & \text{si } b = k_1 \\ 0 & \text{si } b \neq k_1 \end{cases} \quad (30)$$

ahora se reemplazan los resultados y se simplifica para obtener la expresi3n final de la derivada:

$$\begin{aligned} \frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_1,k_1}^{(1)}} &= -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} \frac{1}{P_d^{(i)}} P_d^{(i)} (1 - P_d^{(i)}) \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \right. \\ &\quad \left. + (1 - T_d^{(i)}) \left(\frac{-1}{1 - P_d^{(i)}} \right) P_d^{(i)} (1 - P_d^{(i)}) \omega_{a,b}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \right) \end{aligned} \quad (31)$$

$$\begin{aligned} &= -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} (1 - P_d^{(i)}) \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \right. \\ &\quad \left. - (1 - T_d^{(2,i)}) P_d^{(2,i)} \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \right) \end{aligned} \quad (32)$$

$$\begin{aligned} &= -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \right. \\ &\quad - T_d^{(i)} P_d^{(i)} \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \\ &\quad - P_d^{(i)} \omega_{a,b}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \\ &\quad \left. + T_d^{(i)} P_d^{(i)} \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \right) \end{aligned} \quad (33)$$

$$= -\frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} \left(T_d^{(i)} \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} - P_d^{(i)} \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \right) \quad (34)$$

$$= \frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} (P_d^{(i)} - T_d^{(i)}) \omega_{b,d}^{(2)} a_b^{(2,i)} (1 - a_b^{(2,i)}) \varphi_{j_1}^{(1,i)} \quad (35)$$

reemplazando b por k_1 se tiene:

$$\boxed{\frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_1,k_1}^{(1)}} = \frac{1}{m} \sum_{i=1}^m \sum_{d=1}^{S_3} (P_d^{(i)} - T_d^{(i)}) \omega_{k_1,d}^{(2)} a_{k_1}^{(2,i)} (1 - a_{k_1}^{(2,i)}) x_{j_1}^{(i)}} \quad (36)$$

5. **Implementar el algoritmo de optimizaci3n:** A partir de las derivadas obtenidas se puede implementar un algoritmo de optimizaci3n para encontrar los valores de los pesos. Se continua tomando como referencia el algoritmo de gradiente descendente. Entonces la actualizaci3n de los par3metros viene dada por:

$$\omega_{j_2,k_2,t+1}^{(2)} = \omega_{j_2,k_2,t}^{(2)} - \alpha \frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_2,k_2,t}^{(2)}} \quad (37)$$

y

$$\omega_{j_1, k_1, t+1}^{(1)} = \omega_{j_1, k_1, t}^{(1)} - \alpha \frac{\partial C(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})}{\partial \omega_{j_1, k_1, t}^{(1)}} \quad (38)$$

siendo t el índice de la iteración del algoritmo de optimización.

Así, los resultados de clasificación empleando la red entrenada se muestran en la [Figura 5](#), [Figura 6](#), [Figura 7](#). Para cada una se muestra el mapa de probabilidades correspondiente a cada neurona de salida, la frontera de decisión (la cual se genera tomando el índice de la neurona de salida donde se generó la mayor probabilidad) y el costo obtenido en cada iteración del algoritmo de búsqueda (GD). En todos los casos se utilizó un valor de $\alpha = 0.5$, 2000 iteraciones y los pesos fueron inicializados aleatoriamente con distribución uniforme en un rango $[0, 1]$. Asimismo, la [Figura 5](#) corresponde a una RNA de cinco neuronas en la capa oculta, la [Figura 6](#) muestra los resultados de una RNA con diez neuronas en la capa oculta y la [Figura 7](#) indica los resultados de una RNA que tiene veinte neuronas en la capa oculta. Nótese que en todos los casos se logra una precisión de 100%, que indica una clasificación “perfecta”, pero depende los requerimientos de una aplicación en particular para poder definir cual podría ser la mejor configuración de RNA.

Cabe destacar que los resultados en la implementación podrían variar puesto que dependen del valor inicial de los pesos (los cuales son generados aleatoriamente). Sin embargo, se alienta al estudiante a experimentar con diferente cantidad de neuronas en la capa oculta a fin de encontrar una posible tendencia en el comportamiento de la frontera de decisión.




Figura 5: Resultado del entrenamiento de la RNA con cinco neuronas en la capa oculta: a) MP para P_1 b) MP para P_2 c) Frontera de decisión d) Costo obtenido para cada iteración del algoritmo de entrenamiento.




Figura 6: Resultado del entrenamiento de la RNA con diez neuronas en la capa oculta: a) MP para P_1 b) MP para P_2 c) Frontera de decisi3n d) Costo obtenido para cada iteraci3n del algoritmo de entrenamiento.




Figura 7: Resultado del entrenamiento de la RNA con veinte neuronas en la capa oculta: a) MP para P_1 b) MP para P_2 c) Frontera de decisión d) Costo obtenido para cada iteración del algoritmo de entrenamiento.

Ejercicios

1. Replicar el ejercicio y los resultados mostrados en este documento