

Aplicaciones básicas de autoencoders

Los autoencoders, más allá de su función fundamental de aprender representaciones comprimidas de datos, encuentran aplicaciones prácticas en diversas tareas de procesamiento de datos. En esta sección exploraremos dos aplicaciones fundamentales: la eliminación de ruido (denoising) y la detección de anomalías.

La capacidad de un autoencoder para eliminar ruido de las señales se basa en un principio fundamental: el ruido no comparte la estructura subyacente de los datos de entrenamiento. Durante el proceso de entrenamiento, el autoencoder aprende a identificar y preservar los patrones significativos presentes en el conjunto de datos, mientras que las perturbaciones aleatorias (el ruido) no forman parte de esta estructura aprendida.

Cuando una señal ruidosa pasa a través del encoder $\mathcal{E}$, este mapea la información a un espacio de menor dimensión. En este proceso de compresión, las componentes de ruido, al no ser características representativas del conjunto de entrenamiento, se atenúan significativamente. El decoder $\mathcal{D}$ posteriormente reconstruye la señal basándose únicamente en las características aprendidas durante el entrenamiento, produciendo una versión "limpia" de la entrada original.

Este comportamiento fue evidenciado en el Ejercicio 2 de la sección anterior, donde evaluamos la capacidad del autoencoder para replicar diferentes tipos de datos. Los resultados mostraron que mientras el autoencoder reproduce fielmente los valores que varían suavemente, su desempeño se degrada considerablemente al enfrentarse a datos con ruido gaussiano añadido. Esta degradación no es una limitación, sino precisamente la propiedad que permite su uso como filtro de ruido: el autoencoder "rechaza" naturalmente las componentes que no reconoce como parte de la distribución de datos aprendida.

El mismo principio fundamental que permite a los autoencoders eliminar ruido puede aplicarse para identificar datos anómalos o atípicos. Si el ruido representa perturbaciones aleatorias que no siguen la estructura de los datos de entrenamiento, las anomalías constituyen patrones sistemáticos que tampoco forman parte de la distribución aprendida por el modelo. Durante el entrenamiento, el autoencoder optimiza sus parámetros para reconstruir con mínimo error los datos que siguen la distribución del conjunto de entrenamiento. Cuando se presenta con una muestra anómala, el encoder $\mathcal{E}$ intenta mapearla al espacio latente, pero al no corresponder a los patrones aprendidos, la representación comprimida resulta inadecuada. Consecuentemente, el decoder $\mathcal{D}$ no puede reconstruir eficientemente esta muestra atípica, resultando en un error de reconstrucción significativamente mayor.

El núcleo de la detección de anomalías reside en la cuantificación precisa del error de reconstrucción para cada muestra analizada. Para una señal de entrada $\mathbf{x}^{(i)} \in \mathbb{R}^n$ y su correspondiente reconstrucción $\hat{\mathbf{x}}^{(i)} = \mathcal{D}[\mathcal{E}(\mathbf{x}^{(i)})] \in \mathbb{R}^n$ generada por el autoencoder, definimos el error de reconstrucción individual como:

$$\varepsilon^{(i)} = \frac{1}{n} \sum_{j=1}^n \left(x_j^{(i)} - \hat{x}_j^{(i)} \right)^2 \quad (1)$$

donde $\varepsilon^{(i)}$ representa el error cuadrático medio para la muestra i -ésima, $x_j^{(i)}$ es el j -ésimo elemento del vector de entrada original, y $\hat{x}_j^{(i)}$ es el elemento correspondiente en la reconstrucción.

Esta métrica de error captura la discrepancia entre la señal original y su reconstrucción, proporcionando una medida que facilita la comparación entre diferentes muestras. Para señales que siguen los patrones aprendidos durante el entrenamiento, $\varepsilon^{(i)}$ será relativamente pequeño, mientras que para patrones anómalos, este valor se incrementará significativamente debido a la incapacidad del autoencoder para reconstruir adecuadamente estructuras no familiares.

El proceso de detección requiere el establecimiento de un umbral de decisión τ que separa los datos normales de los anómalos mediante una regla de clasificación que se puede definir como:

$$\text{Clasificación}(\mathbf{x}^{(i)}) = \begin{cases} \text{Normal} & \text{si } \varepsilon^{(i)} \leq \tau \\ \text{Anómalo} & \text{si } \varepsilon^{(i)} > \tau \end{cases} \quad (2)$$

Esta formulación garantiza que los datos de validación que presenten un error mayor al umbral, sean clasificados como anomalías, mientras que las muestras que presenten errores menores, se clasifique como datos normales.

Ejemplo Resuelto

Para demostrar los principios de eliminación de ruido, implementamos un autoencoder diseñado específicamente para limpiar ondas senoidales contaminadas con ruido gaussiano. El conjunto de datos consiste en 10,000 ondas senoidales generadas con frecuencias aleatorias en el rango $[3.0, 3.5]$ Hz, amplitudes variables entre $[0.5, 1.5]$, y fases distribuidas uniformemente en $[0, 2\pi]$. Cada onda contiene 200 puntos temporales distribuidos en el intervalo $[0, 8\pi]$.

El ruido gaussiano se añade a las señales limpias con desviación estándar $\sigma = 0.3$, creando el conjunto de entrada ruidosa. Esta configuración produce pares de entrenamiento donde la entrada $\mathbf{x}^{(i)}$ corresponde a la onda contaminada y el objetivo $\mathbf{y}^{(i)}$ representa la onda limpia original. El conjunto se divide en 80% para entrenamiento (8,000 muestras) y 20% para evaluación (2,000 muestras). La [Figura 1](#) muestra un ejemplo de onda ruidosa que entra al autoencoder y la onda objetivo con la que se compara la salida del modelo.




Figure 1: Comparación entre datos de entrada y objetivo. Panel superior: ejemplo de onda ruidosa utilizada como entrada al autoencoder. Panel inferior: onda limpia correspondiente utilizada como objetivo durante el entrenamiento.

La arquitectura del autoencoder implementa la configuración [200, 64, 32, 16, 32, 64, 200], constituida por un encoder de tres capas que comprime progresivamente desde 200 dimensiones hasta el cuello de botella de 16 neuronas, seguido de un decoder simétrico que expande la representación de vuelta a las 200 dimensiones originales. El encoder utiliza función de activación ReLU en todas sus capas para introducir no-linealidad, mientras que el decoder emplea ReLU en las capas ocultas y activación lineal en la capa de salida para permitir reconstrucciones con rango completo.

El entrenamiento se ejecuta durante 300 épocas utilizando mini-batches de tamaño 64 con tasa de aprendizaje $\alpha = 0.2$ y descenso de gradiente con momento ($\beta = 0.9$). La función de costo corresponde al error cuadrático medio entre las ondas objetivo limpias y las reconstrucciones generadas por el autoencoder a partir de las entradas ruidosas.




Figure 2: Resultados de la eliminación de ruido. Columna izquierda: ondas ruidosas de entrada para dos ejemplos de prueba. Columna derecha: comparación entre ondas limpias objetivo (línea sólida) y reconstrucciones generadas por el autoencoder (línea discontinua).

Los resultados de la reducción de ruido se presentan en la [Figura 2](#), donde se observa que el autoencoder genera reconstrucciones que siguen el contorno de las ondas objetivo, eliminando efectivamente las perturbaciones introducidas por el ruido gaussiano mientras preserva las características fundamentales de frecuencia, amplitud y fase de las señales originales.

Ejemplo Resuelto

Para ilustrar los principios de detección de anomalías, implementamos un autoencoder entrenado exclusivamente con ondas senoidales "normales" para posteriormente evaluar su capacidad de identificar patrones anómalos. El conjunto de entrenamiento consiste en 2,000 ondas senoidales con frecuencias restringidas al rango $[2.8, 3.2]$ Hz, amplitudes variables entre $[0.5, 1.5]$, y fases distribuidas uniformemente en $[0, 2\pi]$. Cada onda contiene 100 puntos temporales distribuidos en el intervalo $[0, 8\pi]$.

El conjunto de evaluación incluye 200 ondas normales (siguiendo la misma distribución del entrenamiento) y 200 ondas anómalas generadas con frecuencias significativamente diferentes en el rango $[5.0, 7.0]$ Hz. Esta configuración permite evaluar la capacidad del autoencoder para discriminar entre patrones familiares y desconocidos basándose únicamente en el error de reconstrucción. La [Figura 3](#) muestra los conjuntos normal y anómalo. Las ondas normales presentan oscilaciones de menor frecuencia con envolventes moduladoras suaves, mientras que las ondas anómalas exhiben oscilaciones de mayor frecuencia.




Figure 3: Comparación entre datos normales y anómalos. Panel superior: ejemplos de ondas normales utilizadas durante el entrenamiento con frecuencias en el rango $[2.8, 3.2]$ Hz. Panel inferior: ejemplos de ondas anómalas con frecuencias en el rango $[5.0, 7.0]$ Hz utilizadas únicamente durante la evaluación.

La arquitectura del autoencoder implementa la configuración $[100, 32, 16, 32, 100]$, con un encoder de dos capas que comprime desde 100 dimensiones hasta un cuello de botella de 16 neuronas, seguido de un decoder simétrico. Todas las capas ocultas utilizan activación ReLU, mientras que la capa de salida emplea activación lineal. El entrenamiento se ejecuta durante 200 épocas con mini-batches de tamaño 32 y tasa de aprendizaje $\alpha = 0.01$. El umbral de detección se establece como máximo error de reconstrucción $\text{Max}(\varepsilon^{(i)})$ observado en el conjunto de ondas normales de prueba y se utiliza la regla de clasificación de la Ecuación 2 para clasificar anomalías.

Los resultados de detección se presentan en la [Figura 4](#). Para los datos normales, las reconstrucciones siguen fielmente las formas de onda originales con errores de reconstrucción $\varepsilon^{(i)}$ del orden de 10^{-4} . En contraste, las ondas anómalas producen reconstrucciones que intentan aproximar los patrones de frecuencia aprendidos durante el entrenamiento, resultando en errores $\varepsilon^{(i)}$ del orden de 10^0 , es decir, aproximadamente 10,000 veces mayores que los errores normales.




Figure 4: Columna izquierda: ejemplos de datos normales con sus reconstrucciones y errores correspondientes. Columna derecha: ejemplos de datos anómalos con reconstrucciones deficientes y errores significativamente mayores.

Las métricas de desempeño del sistema de detección se resumen en la [Tabla 1](#). La precisión del 100% en la identificación de anomalías, sin falsos negativos, refleja la diferencia de magnitud en los errores de reconstrucción entre datos normales y anómalos (cuatro órdenes de magnitud), proporcionando una separación clara que facilita la clasificación automática mediante el umbral establecido.

Métrica	Valor
Precision	100.0%
Verdaderos Positivos	200
Verdaderos Negativos	200

Table 1: Resultados del sistema de detección de anomalías usando autoencoder.

Ejercicios

1. Replique los resultados del ejemplo resuelto sobre reducción de ruido. Una vez entrenado el autoencoder con los mismos parámetros y datos de entrenamiento realice lo siguiente:
 - (a) Genere una onda senoidal base limpia con frecuencia 3.2 Hz, amplitud 0.8 y fase $\pi/4$
 - (b) A partir de esta onda base, cree 15 versiones añadiendo ruido gaussiano aleatorio diferente ($\sigma = 0.3$, misma desviación del entrenamiento)
 - (c) Pase todas las ondas ruidosas a través del autoencoder entrenado
 - (d) Visualice en una sola figura las 15 ondas ruidosas superpuestas y las 15 reconstrucciones superpuestas
 - (e) Calcule la desviación estándar entre las ondas ruidosas vs. entre las reconstrucciones
 - (f) Explique por qué múltiples entradas con ruido aleatorio convergen a reconstrucciones similares
2. Implemente un sistema de detección de anomalías que evalúe diferentes grados de anomalía usando ondas senoidales con distintas frecuencias, para ello:
 - (a) Genere el conjunto de entrenamiento con 10000 ondas con frecuencias [2.8, 3.2] Hz:
 - (b) Genere conjuntos de prueba con 500 ondas cada uno:
 - Normales: frecuencias [2.8, 3.2] Hz
 - Levemente anómalas: frecuencias [3.5, 4.0] Hz
 - Moderadamente anómalas: frecuencias [4.5, 5.5] Hz
 - Altamente anómalas: frecuencias [7.0, 9.0] Hz
 - (c) Entrene un autoencoder [100, 32, 16, 32, 100] utilizando los datos de entrenamiento generados en el inciso a)
 - (d) Evalúe el error de reconstrucción para cada conjunto
 - (e) Grafique la distribución de errores para cada grado de anomalía
 - (f) Analice cómo varía el error de reconstrucción con el grado de anomalía
3. Compare el comportamiento de un autoencoder ante problemas de denoising y detección de anomalías simultáneamente:
 - (a) Entrene un autoencoder [50, 20, 50] con ondas senoidales limpias (frecuencias [3.0, 3.5] Hz)
 - (b) Evalúe el autoencoder ante cuatro tipos de datos de prueba:
 - Ondas normales limpias
 - Ondas normales + ruido gaussiano ($\sigma = 0.2$)
 - Ondas anómalas limpias (frecuencias [6.0, 8.0] Hz)
 - Ondas anómalas + ruido gaussiano ($\sigma = 0.2$)
 - (c) Compare los errores de reconstrucción entre los cuatro casos
 - (d) Determine si es posible usar un umbral único para discriminar entre datos normales (con o sin ruido) y datos anómalos
4. Evalúe la robustez de un sistema de detección de anomalías cuando se enfrenta a ruido en los datos de entrada:
 - (a) Entrene un autoencoder [100, 40, 20, 40, 100] con 1000 ondas senoidales perfectas (sin ruido)
 - (b) Genere datos de prueba:
 - 200 ondas normales + ruido leve ($\sigma = 0.1$)

- 200 ondas normales + ruido fuerte ($\sigma = 0.3$)
 - 200 ondas anómalas + ruido leve ($\sigma = 0.1$)
 - 200 ondas anómalas + ruido fuerte ($\sigma = 0.3$)
- (c) Establezca el umbral de detección usando únicamente ondas normales sin ruido
- (d) Calcule precision, para cada nivel de ruido
- (e) Determine el nivel máximo de ruido que el sistema puede tolerar manteniendo un desempeño aceptable, (precisión > 0.9)
- (f) Proponga una estrategia para mejorar la robustez del sistema ante ruido