

Espacio Latente

Hasta ahora hemos utilizado el autoencoder como una red neuronal completa, con ciertas características que permiten relalizar tareas de forma eficiente. sin embargo, la contribución más importante de éste tipo de arquitecturas, se encuentra en la separación de las redes en encoder y decoder y lo que resulta de utilizarlas de manera individual, cuando entrenamos el autoencoder, y utilizamos únicamente el encoder, los datos de salida de la red serán vectores pertenecientes a lo que se conoce como *espacio latente*.

El concepto de *espacio latente* representa una de las contribuciones más significativas de los autoencoders al aprendizaje automático. Este espacio constituye una representación comprimida y estructurada de los datos originales, donde la información esencial se preserva mientras que los detalles redundantes o irrelevantes se descartan. Para comprender intuitivamente este concepto, podemos establecer una analogía con el proceso de resumir un libro extenso: el resumen captura las ideas fundamentales y la estructura narrativa, omitiendo descripciones detalladas y diálogos específicos, pero conservando la esencia que permite reconstruir mentalmente la historia completa.

Desde una perspectiva geométrica, podemos visualizar el espacio latente como un espacio de coordenadas de menor dimensión donde cada punto representa una configuración específica de características aprendidas. Los datos de entrada, que originalmente residen en un espacio de alta dimensión, se proyectan a este espacio comprimido donde las distancias y relaciones entre puntos reflejan similitudes entre los datos originales.




Figure 1: Representación conceptual del flujo de información a través del autoencoder.

La [Figura 1](#) ilustra el proceso completo de codificación y decodificación. Los datos originales se proyectan al espacio latente donde se organizan según características aprendidas, y posteriormente se reconstruyen preservando la información esencial. Formalmente, para un autoencoder con capa latente de dimensión p , el espacio latente $\mathcal{Z} \subset \mathbb{R}^p$ está definido por el conjunto imagen de la función encoder $\mathcal{E} : \mathbb{R}^n \rightarrow \mathbb{R}^p$:

$$\mathcal{Z} = \{\mathbf{z} \in \mathbb{R}^p : \mathbf{z} = \mathcal{E}(\mathbf{x}), \mathbf{x} \in X\} \quad (1)$$

donde X es el conjunto de datos de entrenamiento. Cada punto $\mathbf{z}^{(i)} \in \mathcal{Z}$ representa la codificación de un dato de entrada $\mathbf{x}^{(i)}$, en términos de activaciones:

$$\mathbf{z}^{(i)} = \mathcal{E}(\mathbf{x}^{(i)}) = \begin{bmatrix} a_1^{(L_e, i)} \\ a_2^{(L_e, i)} \\ \vdots \\ a_p^{(L_e, i)} \end{bmatrix} \quad (2)$$

donde L_e denota la capa latente (capa de salida del encoder) y $a_j^{(L_e, i)}$ representa la activación de la j -ésima neurona latente para la muestra i .

Una propiedad fundamental del espacio latente es su capacidad de preservar la información necesaria para la reconstrucción. Esto se expresa matemáticamente a través de la función de reconstrucción compuesta:

$$\mathbf{x}^{(i)} \approx \mathcal{D}[\mathcal{E}(\mathbf{x}^{(i)})] = \mathcal{D}(\mathbf{z}^{(i)}) \quad (3)$$

La calidad de esta aproximación depende de la capacidad del espacio latente para capturar las características esenciales de los datos originales. Cada dimensión del espacio latente puede interpretarse como un "factor" o "característica" aprendida que contribuye a la descripción de los datos.




Figure 2: (a) Interpretación semántica de un espacio latente bidimensional donde cada dimensión representa una característica específica (tamaño y redondez de formas geométricas). (b) Continuidad semántica mostrada mediante una trayectoria que conecta cinco puntos en el espacio latente, donde las formas geométricas cambian gradualmente de pequeño-angular a grande-redondo.

La Figura 2(a) demuestra la organización semántica de un espacio latente bidimensional utilizando formas geométricas como ejemplo ilustrativo. La dimensión z_1 representa el tamaño (pequeño a grande), mientras que z_2 representa la redondez (angular a redondo). Los puntos se distribuyen de manera que formas con características similares ocupan regiones próximas: las formas pequeñas y angulares se ubican en la esquina inferior izquierda, mientras que las grandes y redondas se posicionan en la esquina superior derecha.

La [Figura 2\(b\)](#) ilustra la *continuidad semántica* del espacio latente. La trayectoria conecta cinco puntos que muestran una transición gradual desde formas pequeñas y angulares hasta formas grandes y redondas. Esta continuidad es fundamental: pequeños desplazamientos en el espacio latente producen cambios graduales y coherentes en las características de los datos representados.

Esta continuidad emerge porque la función encoder $\mathcal{E} : \mathbb{R}^n \rightarrow \mathbb{R}^p$ es continua. Dado que $\mathcal{E}$ se construye mediante composición de funciones continuas (transformaciones lineales seguidas de funciones de activación continuas como tanh o sigmoide), la función completa hereda esta propiedad. Formalmente, para datos de entrada similares $\mathbf{x}_1, \mathbf{x}_2$ tales que $\|\mathbf{x}_1 - \mathbf{x}_2\|^2 < \delta$, obtenemos representaciones latentes próximas $\|\mathcal{E}(\mathbf{x}_1) - \mathcal{E}(\mathbf{x}_2)\|^2 < \varepsilon$ para ε suficientemente pequeño. Esto implica que el mapeo preserva la proximidad local entre datos, garantizando que la estructura del espacio latente refleje las relaciones de similitud del espacio original.

La continuidad del decoder $\mathcal{D} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ completa el marco teórico. Al igual que el encoder, $\mathcal{D}$ se construye mediante composición de funciones continuas, heredando esta propiedad. La continuidad del decoder garantiza que para cualquier $\varepsilon > 0$, existe un $\delta > 0$ tal que si $\|\mathbf{z}_1 - \mathbf{z}_2\|^2 < \delta$, entonces $\|\mathcal{D}(\mathbf{z}_1) - \mathcal{D}(\mathbf{z}_2)\|^2 < \varepsilon$.

Esta doble continuidad (encoder y decoder) asegura que el mapeo completo $\mathcal{D} \circ \mathcal{E} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ preserva la estructura local. En términos prácticos, esto significa que los datos similares en el espacio original se mapean a regiones próximas del espacio latente y los puntos cercanos en el espacio latente se decodifican a datos con características similares. La trayectoria mostrada en la [Figura 2\(b\)](#) ejemplifica esta propiedad: cada punto intermedio corresponde a una forma que combina gradualmente las características de los extremos.

Ejemplo Resuelto

Para demostrar experimentalmente la organización y continuidad semántica del espacio latente, implementamos un autoencoder diseñado para procesar ondas gaussianas con parámetros controlados. El conjunto de datos consiste en 10,000 ondas gaussianas generadas con medias distribuidas uniformemente en el rango $[-2.0, 2.0]$ y desviaciones estándar en el rango $[1.0, 2.5]$. Cada onda contiene 50 puntos distribuidos en el intervalo $[-10, 10]$, generadas mediante la función de densidad gaussiana:

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad (4)$$

donde μ representa la media y σ la desviación estándar de cada gaussiana.

La arquitectura del autoencoder implementa la configuración $[50, 64, 32, 2, 32, 64, 50]$, constituyendo un encoder de tres capas que comprime progresivamente desde 50 dimensiones hasta un cuello de botella bidimensional, seguido de un decoder simétrico que expande la representación de vuelta a las 50 dimensiones originales. El encoder utiliza funciones de activación ReLU en las primeras dos capas y sigmoide en la capa latente para mantener las representaciones en un rango acotado, facilitando la visualización del espacio latente. El decoder emplea ReLU en las capas ocultas y activación lineal en la capa de salida para permitir reconstrucciones con rango completo.

El entrenamiento se ejecuta durante 1,000 iteraciones utilizando mini-batches de tamaño 32 con tasa de aprendizaje $\alpha = 0.7$. La función de costo corresponde al error cuadrático medio entre las ondas originales y sus reconstrucciones. Al finalizar el entrenamiento, el error de reconstrucción converge a aproximadamente 9×10^{-6} , indicando que el autoencoder ha aprendido una representación comprimida efectiva de las ondas gaussianas.

Para analizar la organización semántica del espacio latente, generamos conjuntos de ondas con parámetros controlados siguiendo dos estrategias sistemáticas. Primero, mantenemos la media fija en diferentes valores y variamos únicamente la desviación estándar. Segundo, fijamos la desviación estándar y variamos la media. Esta metodología permite observar cómo cada dimensión del espacio latente captura características específicas de las ondas gaussianas.




Figure 3: Organización semántica del espacio latente bidimensional. Panel izquierdo: proyección de ondas con parámetros controlados. Panel central: ondas con media fija y desviación estándar variable. Panel derecho: ondas con desviación estándar fija y media variable.

La Figura 3 revela que el autoencoder aprende una organización semánticamente coherente del espacio latente. Las trayectorias lineales en rojo corresponden a ondas con media fija y desviación estándar variable, mientras que las trayectorias en azul representan ondas con desviación estándar fija y media variable. Esta separación indica que cada dimensión del espacio latente codifica preferentemente una característica específica: una dimensión captura información sobre la posición (media) mientras que la otra codifica información sobre la anchura (desviación estándar) de las gaussianas.




Figure 4: Cuadrícula semántica del espacio latente. Panel izquierdo: líneas de desviación estándar constante con media variable (coloradas por std). Panel derecho: líneas de media constante con desviación estándar variable (coloradas por media).

Para visualizar mejor esta organización, generamos una cuadrícula semántica completa variando sistemáticamente ambos parámetros. La Figura 4 muestra cómo múltiples familias de curvas emergen naturalmente en el espacio latente, donde cada familia corresponde a un valor fijo de uno de los parámetros gaussianos. La continuidad semántica se demuestra mediante la generación de ondas con parámetros que varían gradualmente entre dos extremos. Comenzando con una gaussiana de media $\mu_1 = -1.5$ y desviación estándar $\sigma_1 = 2.5$, y terminando con una gaussiana de media $\mu_2 = 1.5$ y desviación estándar $\sigma_2 = 1.2$, generamos 10 ondas intermedias mediante interpolación lineal de los parámetros: $\mu_t = (1 - t)\mu_1 + t\mu_2$ y $\sigma_t = (1 - t)\sigma_1 + t\sigma_2$ para $t \in [0, 1]$.




Figure 5: Continuidad semántica del espacio latente. Panel izquierdo: trayectoria continua conectando representaciones latentes de ondas con parámetros graduales. Panel derecho: variación gradual de las ondas gaussianas correspondientes.

La Figura 5 confirma la continuidad semántica del espacio latente aprendido. Los puntos consecutivos en la trayectoria latente corresponden a ondas gaussianas que cambian gradualmente tanto en posición como en anchura. La transición suave entre las representaciones latentes refleja la interpolación suave de los parámetros gaussianos subyacentes, demostrando que pequeños desplazamientos en el espacio latente producen cambios coherentes y predecibles en las características de las ondas reconstruidas.

Este experimento proporciona evidencia empírica directa de las propiedades teóricas discutidas anteriormente. La organización semántica emerge naturalmente del proceso de optimización, donde el autoencoder descubre automáticamente que la representación más eficiente separa las características fundamentales (media y desviación estándar) en dimensiones distintas del espacio latente. La continuidad observada valida matemáticamente la propiedad de que funciones continuas (como las redes neuronales con activaciones continuas) preservan la estructura topológica local, mapeando ondas similares a regiones próximas del espacio de representación comprimida.

Ejercicios

1. Analice la organización del espacio latente de un autoencoder entrenado con funciones polinomiales de segundo grado.
 - (a) Genere 10,000 funciones cuadráticas de la forma $f(x) = ax^2 + bx + c$ donde $a \in [0.5, 2.0]$, $b \in [-3.0, 3.0]$, $c \in [-2.0, 2.0]$, evaluadas en 30 puntos del intervalo $[-5, 5]$
 - (b) Entrene un autoencoder con 3 dimensiones latentes utilizando estas funciones
 - (c) Extraiga las representaciones latentes tridimensionales $\mathbf{z} \in \mathbb{R}^3$ para todo el conjunto de datos

- (d) Genere conjuntos de prueba manteniendo dos parámetros fijos y variando el tercero sistemáticamente
 - (e) Visualice las trayectorias en el espacio latente 3D para cada conjunto de prueba
2. Explore las propiedades de continuidad semántica del espacio latente utilizando funciones trigonométricas.
- (a) Genere 10,000 funciones de la forma $f(x) = A \sin(\omega x + \phi)$ donde $A \in [0.5, 2.0]$ (amplitud), $\omega \in [1.0, 4.0]$ (frecuencia), $\phi \in [0, 2\pi]$ (fase), evaluadas en 40 puntos del intervalo $[0, 4\pi]$
 - (b) Entrene un autoencoder con espacio latente bidimensional
 - (c) Seleccione dos funciones extremas: $f_1(x) = 0.5 \sin(1.0x + 0)$ y $f_2(x) = 2.0 \sin(4.0x + \pi)$
 - (d) Genere 20 funciones intermedias interpolando linealmente los parámetros: $A_t = (1 - t)A_1 + tA_2$, $\omega_t = (1 - t)\omega_1 + t\omega_2$, $\phi_t = (1 - t)\phi_1 + t\phi_2$ para $t \in [0, 1]$
 - (e) Codifique estas 22 funciones (extremas + intermedias) utilizando el encoder entrenado
 - (f) Visualice la trayectoria resultante en el espacio latente bidimensional
 - (g) Decodifique puntos intermedios en la trayectoria latente y compare con las funciones interpoladas originales
3. Compare la eficiencia de compresión entre diferentes dimensiones del espacio latente.
- (a) Genere un conjunto de 10,000 ondas gaussianas siguiendo la misma distribución del Ejemplo Resuelto
 - (b) Entrene cinco autoencoders idénticos con arquitecturas donde $p \in \{1, 2, 4, 8, 16\}$
 - (c) Grafique error de reconstrucción vs. dimensión latente y relación de compresión $r = n/p$ vs. dimensión latente
 - (d) Determine el punto óptimo que balancee compresión y calidad de reconstrucción
 - (e) Analice cómo la interpretabilidad de las dimensiones latentes cambia con p
 - (f) Para el caso $p = 1$, investigue qué característica única captura la dimensión latente