

Diplomado “Redes Neuronales Artificiales”

Módulo 2: Autoencoders

Fecha de elaboración: 1 de octubre de 2025

En este documento se describen las actividades a realizar como parte de la evaluación del segundo módulo del diplomado. Las actividades constan de ejercicios donde es necesario realizar un desarrollo matemático y posteriormente un código de programación para validar los resultados. La evidencia de la elaboración de los ejercicios se deberá entregar en forma de reporte.

Periodo de entrega: A partir de la publicación de este documento y hasta antes del 31 de octubre del 2025.

Requisitos para la entrega del reporte:

1. La elaboración de los ejercicios se debe realizar de manera individual.
2. La evidencia de la elaboración de los ejercicios se deberá entregar en forma de reporte a través de un documento en formato pdf.
3. El reporte debe incluir para cada ejercicio:
 - Descripción detallada de las arquitecturas de autoencoders utilizadas
 - Especificación de todos los hiperparámetros empleados (tasa de aprendizaje, número de épocas, tamaño de mini-batch, funciones de activación, etc.)
 - Justificación clara de la elección de arquitecturas e hiperparámetros
 - Análisis de los resultados obtenidos, acompañados de las gráficas y visualizaciones generadas por el código
 - Todas las gráficas deben incluir títulos, etiquetas de ejes y leyendas apropiadas
4. El reporte deberá estar debidamente organizado, respetando el orden de aparición de los ejercicios descritos en este documento. Asimismo, se deberá agregar un índice que indique la página en que se encuentra cada ejercicio.
5. Cada página del reporte debe contener el nombre completo del estudiante en la parte superior de la misma.
6. El lenguaje de programación es python. No está permitido el uso de librerías o funciones “especiales” para resolver los ejercicios.
7. El envío del reporte junto con los códigos de programación se deberá enviar al profesor vía correo electrónico diplomado.nn@outlook.com.

Nota: En caso de no cumplir la totalidad de los requisitos el reporte no será considerado para evaluación.

Ponderación: El peso de esta tarea es 100% sobre la calificación del módulo 2. La ponderación se indica en cada ejercicio y se asigna si se muestra en el reporte la evidencia de la elaboración completa y correcta del mismo.

Elaboró:

Lic. Luis Rey Vargaz Guadarrama

Vo.Bo.

Dr. Juan Moisés Arredondo Velázquez
M.C. Gerardo Uriel Pérez Rojas

Ejercicio 1: Análisis de Compresión y Reconstrucción en Autoencoders (Ponderación 1/3)

En este ejercicio se explorará experimentalmente la relación entre la dimensión del espacio latente y la capacidad de reconstrucción de un autoencoder, utilizando el conjunto de datos MNIST de dígitos manuscritos.

Parte A: Preparación de datos e implementación

Descargue el conjunto de datos MNIST y preprocese las imágenes normalizando los valores de píxeles al rango $[0, 1]$. Utilice 5000 imágenes para entrenamiento y 1000 para prueba. Represente cada imagen de 28×28 píxeles como un vector en $\mathbb{R}^{784}$.

Implemente **diez autoencoders** con las siguientes arquitecturas:

Autoencoder	Arquitectura	Dimensión latente p
A_1	[784, 256, 784]	256
A_2	[784, 128, 784]	128
A_3	[784, 96, 784]	96
A_4	[784, 64, 784]	64
A_5	[784, 48, 784]	48
A_6	[784, 32, 784]	32
A_7	[784, 24, 784]	24
A_8	[784, 16, 784]	16
A_9	[784, 8, 784]	8
A_{10}	[784, 2, 784]	2

Todos los autoencoders deben entrenarse con el mismo número de muestras y los mismos hiperparámetros (número de épocas, tamaño de mini-batch, tasa de aprendizaje, optimizador, función de activación, etc.). Usted debe determinar estos parámetros de forma que el entrenamiento sea efectivo y justificar la elección de dichos parámetros. Registre el error de prueba Δ en cada época para todos los modelos.

Parte B: Error final vs dimensión latente

1. Calcule el error final de reconstrucción Δ_{final} (última época) para cada uno de los diez autoencoders usando el conjunto de prueba y la Ecuación

$$\Delta = \frac{1}{m} \sum_{i=1}^m \sum_{d=1}^n \left(x_d^{(i)} - \mathcal{D}[\mathcal{E}(\mathbf{x}^{(i)})]_d \right)^2 \quad (1)$$

2. Grafique Δ_{final} vs p (dimensión latente) con los 10 puntos experimentales. Describa el comportamiento de la curva. ¿La relación entre p y Δ_{final} es lineal, exponencial, potencial o logarítmica? ¿A partir de qué valor de p el error se estabiliza? ¿Qué implica esto sobre la dimensionalidad intrínseca de los dígitos manuscritos?

Parte C: Distribución espacial del error

Para los autoencoders A_2 (128 dim), A_6 (32 dim) y A_{10} (2 dim):

1. Seleccione 50 imágenes del conjunto de prueba.
2. Para cada autoencoder, calcule el error cuadrático por píxel para cada una de las 50 imágenes:

$$e_d^{(i)} = \left(x_d^{(i)} - \mathcal{D}[\mathcal{E}(\mathbf{x}^{(i)})]_d \right)^2$$

donde $d \in [1, 784]$ indica la posición del píxel e $i \in [1, 50]$ indica la imagen.

3. Compute el error promedio por posición sobre las 50 imágenes:

$$\bar{e}_d = \frac{1}{50} \sum_{i=1}^{50} e_d^{(i)}$$

4. Visualice $\bar{e}_d$ como un mapa de calor de 28×28 para cada uno de los tres autoencoders (genere 3 mapas de calor). ¿Existen regiones de la imagen donde el error es consistentemente mayor? ¿Cómo cambia la distribución espacial del error conforme p disminuye? Relacione sus observaciones con el concepto de pérdida inevitable de información discutido en el documento de referencia.

Ejercicio 2: Detección de Anomalías con Autoencoders (Ponderación 1/3)

En este ejercicio se explorará experimentalmente la capacidad de un autoencoder para detectar anomalías en imágenes de dígitos manuscritos del conjunto de datos MNIST. Se evaluará cómo la similitud entre clases afecta el desempeño del sistema de detección.

Parte A: Preparación de datos

Descargue el conjunto de datos MNIST y preprocese las imágenes normalizando los valores de píxeles al rango $[0, 1]$. Para este ejercicio trabajará con dos experimentos que utilizan diferentes pares de clases de dígitos.

Experimento 1: Clases disímiles (0 vs 1)

1. Filtre del conjunto de entrenamiento únicamente las imágenes correspondientes al dígito 0. Estas imágenes se considerarán como datos **normales**. Utilice 2000 imágenes de esta clase para entrenamiento.
2. Del conjunto de prueba, extraiga:
 - 500 imágenes del dígito 0 (datos normales de prueba)
 - 500 imágenes del dígito 1 (datos anómalos de prueba)

Experimento 2: Clases similares (4 vs 9)

1. Filtre del conjunto de entrenamiento únicamente las imágenes correspondientes al dígito 4. Estas imágenes se considerarán como datos **normales**. Utilice 2000 imágenes de esta clase para entrenamiento.
2. Del conjunto de prueba, extraiga:
 - 500 imágenes del dígito 4 (datos normales de prueba)
 - 500 imágenes del dígito 9 (datos anómalos de prueba)

Represente cada imagen de 28×28 píxeles como un vector en $\mathbb{R}^{784}$.

Parte B: Implementación y entrenamiento

Implemente un autoencoder con la arquitectura $[784, 128, 64, 128, 784]$. Esta arquitectura debe ser la misma para ambos experimentos. Los hiperparámetros de entrenamiento (número de épocas, tamaño de mini-batch, tasa de aprendizaje, optimizador, función de activación) también deben ser idénticos en ambos experimentos. Usted debe determinar estos parámetros de forma que el entrenamiento sea efectivo y justificar la elección de los mismos.

Importante:

- Entrene el primer autoencoder únicamente con las 2000 imágenes del dígito 0 del Experimento 1.
- Entrene el segundo autoencoder únicamente con las 2000 imágenes del dígito 4 del Experimento 2.
- Ambos entrenamientos deben usar exactamente los mismos hiperparámetros.

Parte C: Selección de umbral y evaluación del desempeño

Para cada experimento, realice el siguiente procedimiento:

1. Calcule el error de reconstrucción individual $\varepsilon^{(i)}$ para cada una de las imágenes normales de prueba (500 imágenes del dígito 0 para el Experimento 1, y 500 imágenes del dígito 4 para el Experimento 2) usando la ecuación:

$$\varepsilon^{(i)} = \frac{1}{n} \sum_{d=1}^n \left(x_d^{(i)} - \mathcal{D}[\mathcal{E}(\mathbf{x}^{(i)})]_d \right)^2 \quad (2)$$

donde $n = 784$ es la dimensión del vector de entrada, $x_d^{(i)}$ es el d -ésimo elemento del vector de entrada original, y $\mathcal{D}[\mathcal{E}(\mathbf{x}^{(i)})]_d$ es el elemento correspondiente en la reconstrucción generada por el autoencoder.

2. Calcule el error de reconstrucción individual $\varepsilon^{(i)}$ para cada una de las imágenes anómalas de prueba (500 imágenes del dígito 1 para el Experimento 1, y 500 imágenes del dígito 9 para el Experimento 2) usando la misma ecuación.
3. Para determinar el umbral óptimo de detección, evalúe total de 10 de valores de umbral que se encuentren en el rango τ desde el mínimo hasta el máximo error observado en el conjunto de prueba completo (normales + anómalas). Para cada valor de umbral τ_k :

- Clasifique cada muestra usando la regla:

$$\text{Clasificación}(\mathbf{x}^{(i)}) = \begin{cases} \text{Normal} & \text{si } \varepsilon^{(i)} \leq \tau_k \\ \text{Anómalo} & \text{si } \varepsilon^{(i)} > \tau_k \end{cases}$$

- Calcule el accuracy del clasificador:

$$\text{Accuracy} = \frac{\text{Verdaderos Positivos} + \text{Verdaderos Negativos}}{\text{Total de muestras}}$$

donde Verdaderos Positivos son anomalías correctamente identificadas y Verdaderos Negativos son datos normales correctamente identificados.

4. Grafique la relación entre el umbral τ (eje x) y el accuracy (eje y) para cada experimento. Genere dos gráficas: una para el Experimento 1 (0 vs 1) y otra para el Experimento 2 (4 vs 9).
5. Para cada experimento, identifique el umbral τ^* que maximiza el accuracy y reporte:
 - El valor del umbral óptimo τ^*
 - El accuracy máximo alcanzado

Parte D: Comparación y análisis de resultados

1. Seleccione 3 ejemplos de cada tipo (normales y anómalos) de cada experimento. Para cada ejemplo, visualice:
 - La imagen original
 - La imagen reconstruida por el autoencoder
 - El error de reconstrucción $\varepsilon^{(i)}$ correspondiente
2. Compare el accuracy máximo obtenido en ambos experimentos. ¿Cuál experimento presenta mejor desempeño? Explique cualitativamente, (con ayuda de los ejemplo graficados en el inciso anteriore) el por qué.

Ejercicio 3: Exploración de las Propiedades del Espacio Latente (Ponderación 1/3)

En este ejercicio se analizará experimentalmente la estructura geométrica del espacio latente de un autoencoder entrenado con dígitos manuscritos. Se explorarán tres propiedades fundamentales: continuidad semántica, organización por clases y comportamiento en regiones de intersección.

Parte A: Preparación e implementación

Descargue el conjunto de datos MNIST y preprocese las imágenes normalizando los valores de píxeles al rango $[0, 1]$. Para este ejercicio, seleccione únicamente las imágenes correspondientes a **cuatro dígitos**: 0, 1, 4 y 9. Utilice 1500 imágenes de cada clase para entrenamiento (6000 imágenes totales) y 300 imágenes de cada clase para prueba (1200 imágenes totales). Represente cada imagen de 28×28 píxeles como un vector en $\mathbb{R}^{784}$.

Implemente un autoencoder con arquitectura $[784, 256, 128, 2, 128, 256, 784]$, que comprime las imágenes a un espacio latente bidimensional $\mathcal{Z} \subset \mathbb{R}^2$. Utilice funciones de activación apropiadas en cada capa y entrene el modelo con hiperparámetros que garanticen convergencia efectiva. Justifique la elección de estos parámetros.

Parte B: Visualización y organización del espacio latente

1. Codifique todas las imágenes del conjunto de prueba (1200 imágenes) utilizando el encoder entrenado $\mathcal{E} : \mathbb{R}^{784} \rightarrow \mathbb{R}^2$ para obtener sus representaciones latentes $\mathbf{z}^{(i)} = \mathcal{E}(\mathbf{x}^{(i)}) \in \mathbb{R}^2$.
2. Genere un diagrama de dispersión del espacio latente bidimensional donde cada punto represente una imagen, utilizando colores distintos para cada clase (0, 1, 4, 9). Asegúrese de incluir una leyenda clara.
3. Analice la distribución espacial observada en el diagrama:
 - Describa cómo se organizan las representaciones de cada clase en el espacio latente
 - Identifique y caracterice las relaciones espaciales entre las diferentes clases
 - Documente cualquier patrón, estructura o fenómeno relevante que observe

Parte C: Exploración de la continuidad semántica

Para demostrar la propiedad de continuidad del espacio latente, realice el siguiente experimento:

1. Seleccione dos imágenes específicas del conjunto de prueba que pertenezcan a clases diferentes:
2. Codifique ambas imágenes para obtener sus representaciones latentes:

$$\mathbf{z}_A = \mathcal{E}(\mathbf{x}_A), \quad \mathbf{z}_B = \mathcal{E}(\mathbf{x}_B)$$

3. Genere una trayectoria lineal en el espacio latente con 20 puntos intermedios mediante interpolación:

$$\mathbf{z}_t = (1 - t)\mathbf{z}_A + t\mathbf{z}_B, \quad t \in \left\{0, \frac{1}{19}, \frac{2}{19}, \dots, \frac{20}{19}, 1\right\}$$

4. Decodifique cada punto de la trayectoria para obtener las imágenes correspondientes:

$$\mathbf{x}_t = \mathcal{D}(\mathbf{z}_t)$$

5. Visualice:

- La trayectoria $\{\mathbf{z}_t\}$ en el espacio latente bidimensional, supepuesta sobre el diagrama de dispersión de la Parte B
 - Las 20 imágenes reconstruidas $\{\mathbf{x}_t\}$ en orden secuencial, mostrando la transición visual desde el dígito de una clase hasta el dígito de la otra clase
6. Analice cualitativamente el proceso de transición observado en las imágenes reconstruidas. Describa las características de la evolución visual a lo largo de la trayectoria, incluyendo observaciones sobre la naturaleza de las imágenes intermedias y el comportamiento general de la transformación.

Parte D: Análisis de regiones de intersección

Para investigar el comportamiento del autoencoder en regiones donde coexisten múltiples clases:

1. Identifique visualmente en el diagrama de la Parte B una región de intersección significativa entre dos clases. Registre las coordenadas aproximadas (z_1^*, z_2^*) del centro de esta región.
2. Genere una cuadrícula de exploración de $7 \times 7 = 49$ puntos centrada en (z_1^*, z_2^*) con espaciado uniforme de 0.3 unidades en cada dimensión:

$$\mathbf{z}_{i,j} = \begin{bmatrix} z_1^* + (i-4) \cdot 0.3 \\ z_2^* + (j-4) \cdot 0.3 \end{bmatrix}, \quad i, j \in \{1, 2, \dots, 7\}$$

3. Decodifique cada punto de la cuadrícula: $\mathbf{x}_{i,j} = \mathcal{D}(\mathbf{z}_{i,j})$
4. Visualice las 49 imágenes decodificadas en formato de cuadrícula 7×7 , preservando las posiciones relativas de los puntos en el espacio latente.
5. Analice los resultados:
 - ¿Las imágenes reconstruidas en la región de intersección son reconocibles como dígitos específicos o presentan ambigüedad visual?
 - ¿Observa una transición gradual entre las características de las clases conforme se desplaza por la cuadrícula?
 - ¿Existen puntos en la cuadrícula que generan reconstrucciones de baja calidad o imágenes que no se asemejan a ninguno de los cuatro dígitos? Si es así, ¿a qué podría deberse esto?