

Gradiente descendente con momento

El gradiente descendente estándar actualiza los parámetros utilizando únicamente la información del gradiente actual. Para una función $f(x)$, la regla de actualización es:

$$x_{t+1} = x_t - \alpha \nabla f(x_t) \quad (1)$$

Donde α es la tasa de aprendizaje y $\nabla f(x_t)$ es el gradiente evaluado en x_t . Sin embargo, este método presenta limitaciones significativas como convergencia lenta en regiones con gradientes pequeños, oscilaciones excesivas en valles estrechos, y susceptibilidad a quedar atrapado en mínimos locales.

El *gradiente descendente con momento* aborda estas limitaciones incorporando información histórica del gradiente mediante un término de velocidad v_t . Este método mantiene una "memoria" de las direcciones de descenso previas, proporcionando inercia al proceso de optimización.

$$v_t = \beta v_{t-1} + \alpha \nabla f(x_{t-1}) \quad (2)$$

donde $\beta \in [0, 1)$ es el coeficiente de momento (típicamente $\beta = 0.9$), α es la tasa de aprendizaje, y la velocidad inicial es $v_0 = 0$. La regla de actualización de parámetros se modifica como:

$$x_t = x_{t-1} - v_t \quad (3)$$

El algoritmo de gradiente descendente con momento procede de la siguiente manera:

1. Inicializar: x_0 (posición inicial), $v_0 = 0$ (velocidad inicial)
2. Para $t = 1, 2, \dots$ hasta convergencia:
 - (a) Calcular el gradiente: $g_t = \nabla f(x_{t-1})$
 - (b) Actualizar velocidad: $v_t = \beta v_{t-1} + \alpha g_t$
 - (c) Actualizar parámetros: $x_t = x_{t-1} - v_t$
 - (d) Evaluar función: $f(x_t)$

La introducción del término de momento proporciona al algoritmo tres ventajas fundamentales. En dirección consistentes del gradiente, la velocidad se acumula, acelerando la convergencia. Las oscilaciones se reducen cuando los gradientes cambian de dirección frecuentemente y La inercia puede ayudar a superar mínimos locales pequeños.

Matemáticamente, la velocidad v_t constituye un promedio ponderado exponencialmente decreciente de todos los gradientes pasados:

$$v_t = \alpha \sum_{i=0}^{t-1} \beta^i \nabla f(x_{t-1-i}) \quad (4)$$

Esta expansión muestra que gradientes más recientes tienen mayor peso, mientras que la influencia de gradientes antiguos decrece exponencialmente.

Ejemplo resuelto

Para ilustrar las diferencias entre ambos métodos, consideremos la función cuadrática:

$$f(x) = (x - 5)^2 + 10 \quad (5)$$

cuyo gradiente es $\nabla f(x) = 2(x - 5)$. Esta función tiene un único mínimo global en $x^* = 5$.

Implementamos ambos algoritmos con parámetros: $x_0 = 10$, $\alpha = 0.02$, $\beta = 0.9$, y $v_0 = 0$. La [Tabla 1](#) muestra la evolución de ambos métodos durante las primeras 5 iteraciones.

Iteración t	Gradiente Descendente		GD con Momento	
	x_t	$\nabla f(x_t)$	x_t	$\nabla f(x_t)$
0	10.000	10.000	10.000	10.000
1	9.800	9.600	9.800	9.600
2	9.608	9.216	9.428	8.856
3	9.424	8.847	8.916	7.832
4	9.247	8.493	8.299	6.597
5	9.077	8.154	7.611	5.222

Table 1: Comparación numérica entre gradiente descendente estándar y con momento para la función $f(x) = (x - 5)^2 + 10$. Se observa que el método con momento converge más rápidamente hacia el mínimo.

La [Figura 1](#) muestra las trayectorias de optimización para ambos métodos. Se observa que el gradiente descendente con momento converge más rápidamente debido a la acumulación de velocidad en la dirección consistente del gradiente.




Figure 1: Trayectorias de optimización para la función $f(x) = (x - 5)^2 + 10$. (a) Gradiente descendente estándar. (b) Gradiente descendente con momento. Los puntos coloreados muestran la progresión temporal.

Ejemplo Resuelto

Una ventaja crucial del gradiente descendente con momento es su capacidad para escapar de mínimos locales poco profundos. Para demostrar esta propiedad, consideremos la función:

$$g(x) = 8 \sin(x) + x^2 \quad (6)$$

cuyo gradiente es $\nabla g(x) = 8 \cos(x) + 2x$. Esta función presenta múltiples mínimos locales debido al término sinusoidal, con un mínimo global aproximadamente en $x^* \approx -1.43$.

Utilizando ambos métodos con punto de inicio $x_0 = 8$ (posición que permite observar la navegación a través de múltiples extremos), tasa de aprendizaje $\alpha = 0.1$ y coeficiente de momento $\beta = 0.9$, observamos comportamientos diferentes. Por un lado el gradiente descendente tradicional queda atrapado en el mínimo local cerca de $x \approx -2.2$, mientras que para el gradiente descendente con momentum, la inercia acumulada le permite superar la barrera energética y continuar hacia el mínimo global.




Figure 2: Análisis del escape de mínimos locales para la función $g(x) = 8 \sin(x) + x^2$. (a) Trayectorias de optimización: los círculos rojos muestran el gradiente descendente estándar, mientras que los cuadrados azules muestran el gradiente descendente con momento. (b) Comparación de convergencia utilizando ambos optimizadores.

La Figura 2 ilustra este fenómeno. El panel (a) muestra que el gradiente descendente estándar queda atrapado en un extremo local, mientras que el método con momento mantiene suficiente "inercia" para navegar a través de la superficie compleja de la función. El panel (b) confirma que, aunque el método con momento puede presentar oscilaciones iniciales, eventualmente encuentra una solución significativamente mejor.

Este comportamiento se debe a que la velocidad acumulada v_t puede mantener el algoritmo en movimiento incluso cuando el gradiente actual es pequeño (cerca de ceros locales). Matemáticamente, si el algoritmo se aproxima a un mínimo local con gradiente $\nabla g(x) \approx 0$, la actualización del gradiente descendente estándar se vuelve despreciable: $x_{t+1} \approx x_t$. Sin embargo, en el método con momento, la velocidad puede seguir siendo significativa: $v_{t+1} = \beta v_t + \alpha \cdot 0 = \beta v_t$, permitiendo que $x_{t+1} = x_t - \beta v_t$ continúe alejándose del mínimo local.

Ejercicios

1. Implemente y compare ambos métodos de optimización para diferentes funciones objetivo.
 - (a) Para la función $f_1(x) = 0.5x^2 + 3x - 2$, utilice gradiente descendente estándar y con momento partiendo de $x_0 = 5$
 - (b) Configure los parámetros: $\alpha = 0.1$ y $\beta = 0.8$ para el método con momento
 - (c) Ejecute ambos algoritmos durante 20 iteraciones y registre la posición x_t en cada iteración
 - (d) Grafique las trayectorias de convergencia y compare el número de iteraciones necesarias para alcanzar el mínimo con precisión de 0.01
 - (e) Analice cómo la diferencia entre métodos se relaciona con la curvatura de la función
2. Investigue el efecto del coeficiente de momento en la convergencia.
 - (a) Utilizando la función $f_2(x) = (x + 2)^2 + 5$ con punto inicial $x_0 = 8$ y $\alpha = 0.05$
 - (b) Implemente gradiente descendente con momento para diferentes valores de $\beta \in \{0.0, 0.3, 0.6, 0.9, 0.95\}$

- (c) Para cada valor de β , ejecute el algoritmo durante 50 iteraciones
 - (d) Grafique la evolución del valor de la función $f_2(x_t)$ para cada β en una sola figura
 - (e) Determine el valor óptimo de β que minimiza el número de iteraciones para convergencia
 - (f) Explique teóricamente por qué valores extremos de β (muy cercanos a 0 o 1) pueden ser problemáticos
3. Evalúe la robustez de gradiente descendente con momento ante diferentes tasas de aprendizaje.
- (a) Utilice la función del ejemplo resuelto: $g(x) = 8\sin(x) + x^2$ con $x_0 = -2.5$
 - (b) Configure $\beta = 0.9$ y varíe la tasa de aprendizaje: $\alpha \in \{0.001, 0.01, 0.05, 0.1, 0.2\}$
 - (c) Para cada α , ejecute gradiente descendente estándar y con momento durante 100 iteraciones
 - (d) Registre si cada método logra escapar del mínimo local inicial (definir escape como alcanzar $x < -1.8$)
 - (e) Grafique la velocidad v_t a lo largo de las iteraciones para el método con momento
 - (f) Determine el rango de tasas de aprendizaje que permite escape exitoso para cada método
 - (g) Proponga una explicación de por qué tasas muy altas o muy bajas pueden impedir el escape