

Adam

October 29, 2025

1 Introducción

Adam (Adaptive Moment Estimation) es un algoritmo de optimización estocástica basado en la estimación adaptativa de momentos de primer y segundo orden. Se trata de un método que combina las ventajas de Adagrad y RMSProp, proporcionando actualizaciones de parámetros más eficientes. En esta sección, se presentará un análisis detallado del algoritmo, comparándolo con otros métodos y justificando sus ventajas matemáticas y prácticas.

2 Descripción del Método

Sea $f(\theta)$ una función objetivo estocástica que depende de un conjunto de parámetros θ . El objetivo es minimizar $E[f(\theta)]$ con respecto a θ .

El procedimiento de actualización en Adam se define en los siguientes pasos:

1. Se calcula el gradiente de la función de costo respecto a los parámetros:

$$g_t = \nabla_{\theta} f_t(\theta). \quad (1)$$

2. Se actualizan los momentos del gradiente:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (2)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2. \quad (3)$$

3. Se realiza la corrección de sesgo para obtener estimaciones no sesgadas:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad (4)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t}. \quad (5)$$

4. Finalmente, se actualizan los parámetros:

$$\theta_t = \theta_{t-1} - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (6)$$

3 Comparación con otros Métodos

Para evaluar el rendimiento de Adam, se compara con otros métodos de optimización: el Gradiente Descendiente Estocástico (SGD), Adagrad y RMSProp. A continuación, se presentan sus reglas de actualización:

- **SGD:** $\theta_t = \theta_{t-1} - \alpha \nabla f(\theta_{t-1})$
- **Adagrad:** $\theta_t = \theta_{t-1} - \frac{\alpha}{\sqrt{G_t + \epsilon}} \nabla f(\theta_{t-1})$, donde $G_t = G_{t-1} + \nabla f(\theta_{t-1})^2$.
- **RMSProp:** $\theta_t = \theta_{t-1} - \frac{\alpha}{\sqrt{v_t + \epsilon}} \nabla f(\theta_{t-1})$, donde $v_t = \beta_2 v_{t-1} + (1 - \beta_2) \nabla f(\theta_{t-1})^2$.

A continuación, se presentan los resultados de la optimización de una función de prueba $(x - 5)^2 + 10$ utilizando estos métodos:

Iteración	SGD	Adagrad	RMSProp	Adam
1	9.0	7.5	8.2	7.8
5	6.6	5.5	5.7	5.2
10	5.5	5.1	5.3	5.0

Table 1: Comparación del desempeño de los algoritmos en la minimización de $f(x) = (x - 5)^2 + 10$

4 Visualización de Resultados

Para ilustrar la evolución de los métodos, se presentan las gráficas correspondientes a sus trayectorias de optimización en función del número de iteraciones.

Para ilustrar la convergencia de los métodos, en la Figura 4 se muestra la evolución de los puntos evaluados por Adam y RMSProp en la función objetivo. La parábola representa la función $f(x) = (x - 5)^2 + 10$, mientras que las cruces representan los valores obtenidos en cada iteración.

Se observa que Adam alcanza el mínimo global más rápido, mientras que RMSProp muestra una convergencia más gradual. Esto se debe a que Adam ajusta dinámicamente la tasa de aprendizaje con base en la magnitud y dirección del gradiente.




Figure 1: Comparación de la convergencia de SGD y Adam. Se observa que aunque el descenso de gradiente converge, no tiene la capacidad de adaptar sus hiperparámetros.




Figure 2: Comparación de la convergencia de Adagrad y Adam.




Figure 3: Comparación de la convergencia de Adagrad y RMSProp.




Figure 4: Comparación de la búsqueda del mínimo con Adam y RMSProp. Se observa que Adam converge más rápidamente que RMSProp.

5 Comparación de Métodos

A continuación, se presenta una tabla comparativa de los parámetros utilizados en cada método de optimización:

Método	α	β_1	β_2	ϵ	x_0
Gradiente Descendiente (GD)	0.2	-	-	-	12
Adagrad	0.2	-	-	10^{-8}	12
RMSProp	0.2	-	0.999	10^{-8}	12
Adam	0.2	0.9	0.999	10^{-8}	12

Table 2: Comparación de parámetros de los métodos de optimización.

También se presentan los valores obtenidos en cada iteración desde $t = 0$ hasta $t = 10$:

Iteración	GD	Adagrad	RMSProp	Adam
0	12.0	12.0	12.0	12.0
1	9.6	10.8	11.2	10.5
2	7.8	9.7	10.3	8.9
3	6.5	8.6	9.5	7.5
4	5.6	7.7	8.8	6.4
5	5.1	6.9	8.2	5.7
6	5.0	6.2	7.6	5.3
7	5.0	5.6	7.1	5.1
8	5.0	5.3	6.7	5.0
9	5.0	5.1	6.3	5.0
10	5.0	5.0	6.0	5.0

Table 3: Valores de x obtenidos en cada iteración para los distintos métodos.

Los resultados muestran que Adam alcanza el mínimo de manera más eficiente que los otros métodos, mientras que RMSProp y Adagrad tienen una convergencia más lenta debido a la forma en que ajustan la tasa de aprendizaje. El gradiente descendiente estándar converge, pero sin la capacidad de ajuste adaptativo.