

Diplomado “Redes Neuronales Artificiales”

Módulo 3: GAN's

Fecha de elaboración: 29 de octubre de 2025

En este documento se describen las actividades a realizar como parte de la evaluación del tercer módulo (GAN's) del diplomado. Las actividades constan de ejercicios donde es necesario realizar un desarrollo matemático y posteriormente un código de programación para validar los resultados. La evidencia de los ejercicios se deberá entregar en forma de reporte.

Periodo de entrega: A partir de la publicación de este documento y hasta antes del 30 de noviembre de 2025.

Requisitos para la entrega del reporte:

1. La elaboración de los ejercicios se debe realizar de manera individual.
2. La evidencia de la elaboración de los ejercicios se deberá entregar en forma de reporte en formato PDF.
3. El reporte debe incluir para cada ejercicio:
 - Descripción detallada de las arquitecturas de generador y discriminador utilizadas.
 - Especificación de todos los hiperparámetros empleados (tasa de aprendizaje, número de épocas, tamaño de mini-batch, funciones de activación, etc.).
 - Justificación clara de la elección de arquitecturas e hiperparámetros.
 - Análisis de los resultados obtenidos, acompañados de las gráficas y visualizaciones generadas por el código.
 - Todas las gráficas deben incluir títulos, etiquetas de ejes y leyendas apropiadas.
4. El reporte deberá estar debidamente organizado, respetando el orden de aparición de los ejercicios. Incluir un índice que indique la página en que se encuentra cada ejercicio.
5. Cada página del reporte debe contener el nombre completo del estudiante en la parte superior.
6. El lenguaje de programación es Python. No está permitido el uso de librerías o funciones “especiales”.
7. El envío del reporte junto con los códigos de programación se deberá realizar por correo electrónico a diplomado.nn@outlook.com.

Nota: En caso de no cumplir la totalidad de los requisitos el reporte no será considerado para evaluación.

Ponderación: El peso de esta tarea es 100% sobre la calificación del módulo 3. La ponderación se indica en cada ejercicio y se asigna si se muestra en el reporte la evidencia de la elaboración completa y correcta del mismo

Elaboró:

M.C. Gerardo Uriel Pérez Rojas

Vo.Bo.

Dr. Juan Moisés Arredondo Velázquez

Lic. Luis Rey Vargaz Guadarrama

Ejercicio 1: Análisis de calidad y varianza de generación en GANs con MNIST (Ponderación 1/3)

En este ejercicio se evaluará cómo la dimensión del espacio latente y la arquitectura del generador influyen en la calidad y la diversidad (varianza) de muestras generadas sobre MNIST.

Datos

Usar MNIST (imágenes 28×28). Normalizar a $[0, 1]$.

Parte A: Arquitecturas y entrenamiento (exigente)

Implemente y entrene tres GANs que difieran en la arquitectura del generador y en la dimensión latente z :

- a) GAN-G1: generador simple, $z = 16$ (2 capas densas, activación ReLU/Tanh en salida).
- b) GAN-G2: generador intermedio, $z = 64$ (3 capas).
- c) GAN-G3: generador profundo, $z = 128$ (al menos 4 capas, incluir bloque residual simple).

El discriminador será el mismo en los tres experimentos (arquitectura definida por usted; justificar). Mantener idénticos los hiperparámetros entre modelos (optimizador, lr, batch size, épocas). Debe:

- Implementar las capas desde cero o usando sólo los scripts que se desarrollaron en clase; documentar y comentar cada rutina.
- Implementar optimizador de su preferencia con sus actualizaciones explícitas.
- Registrar y guardar por época: pérdidas (D real, D fake, D total, G) y medias.
- Sembrar aleatoriedad y documentar la semilla.

Parte B: Funciones de Loss (ampliada)

Para cada modelo entrene con las siguientes variantes de función objetivo (todas ellas requieren implementación matemática y numérica propia):

- i. **BCE clásico (vanilla)**: usar la pérdida de entropía cruzada binaria para D y la pérdida no saturante para G .
- ii. **Least-Squares GAN (LSGAN)**: para D minimice

$$L_D = \frac{1}{2} \mathbb{E}_{x \sim p_{\text{data}}} [(D(x) - 1)^2] + \frac{1}{2} \mathbb{E}_{z \sim p_z} [D(G(z))^2], \quad (1)$$

y para G minimice

$$L_G = \frac{1}{2} \mathbb{E}_{z \sim p_z} [(D(G(z)) - 1)^2]. \quad (2)$$

- iii. **Hinge loss**: implementar la versión hinge común en GANs:

$$L_D = \mathbb{E}[\max(0, 1 - D(x))] + \mathbb{E}[\max(0, 1 + D(G(z)))], \quad (3)$$

$$L_G = -\mathbb{E}[D(G(z))]. \quad (4)$$

Para cada variante: justificar por qué puede favorecer estabilidad, diversidad o calidad.

Parte C: Medición de diversidad y calidad

Para cada combinación (arquitectura $\times$ loss), en la última época:

1. Genere $N = 5000$ muestras $x_i \in \mathbb{R}^{784}$.
2. Calcule la varianza por píxel

$$\text{Var}_d = \frac{1}{N} \sum_{i=1}^N (x_{i,d} - \mu_d)^2, \quad \mu_d = \frac{1}{N} \sum_{i=1}^N x_{i,d}.$$

3. Calcule la varianza promedio

$$\overline{\text{Var}} = \frac{1}{784} \sum_{d=1}^{784} \text{Var}_d.$$

Parte D: Gráficas y diagnósticos (obligatorio)

Genere y entregue las siguientes gráficas por experimento:

- Curvas por época: **Loss** de D (real, fake, total) y de G (por variante de loss). Indicar promedios y desviaciones en barras de confianza.
- Curvas de **confianza** del discriminador: histogramas y curvas ROC/Precision-Recall que muestren la distribución de $D(x)$ para reales y generados por época.
- **Accuracy** del discriminador por época (definición clásica): $\text{Accuracy} = (\text{TP} + \text{TN}) / \text{Total}$; entregue además sensibilidad (recall) y especificidad (true negative rate) por época.
- Mapa de calor 28×28 de Var_d .

Parte E: Análisis crítico y experimento control

1. Identificar si la variación en $\overline{\text{Var}}$ proviene de la capacidad del generador o del tamaño del latente: diseñe un experimento de control (por ejemplo, aumentar capas del generador manteniendo z fijo, o mantener arquitectura y variar z) y formule una hipótesis nula que pueda ser contrastada estadísticamente (p.ej. ANOVA sobre $\overline{\text{Var}}$).
2. Realice la prueba y presente contraste estadístico (p-valor, con nivel $\alpha = 0.05$) y su interpretación.

Ejercicio 2: Transferencia y robustez en NIST / EMNIST con Conditional GANs (Ponderación 1/3)

En este ejercicio se evaluará la capacidad de una GAN condicional (cGAN) para modelar distribuciones relacionadas (EMNIST y NIST) y medir la robustez frente a cambios entre conjuntos. Se solicita implementación propia de condicionamiento, cálculo de accuracy por clase, y análisis de coverage/mode dropping por clase.

Apéndice teórico: cGAN — conformación, entrenamiento y ventajas

Conformación básica

Una GAN condicional (cGAN) extiende la formulación clásica incorporando una condición y (p. ej. etiqueta de clase, vector de atributos o imagen guía) tanto en el generador como en el discriminador. Modela $p(x | y)$ en lugar de la marginal $p(x)$. La condición se incorpora típicamente por concatenación de $[z; y]$ en G , concatenación o inyección por proyección en D .

Formulación objetivo (condicional)

$$\min_G \max_D \mathbb{E}_{x, y \sim p_{\text{data}}} [\log D(x, y)] + \mathbb{E}_{z \sim p_z, y \sim p_y} [\log (1 - D(G(z, y), y))].$$

Ventajas principales

- Generación dirigida por etiqueta/atributo.
- Mejor diagnóstico y evaluación por clase ($\overline{\text{Var}}_c$).

Datos

Usar EMNIST (Balanceada o de letras)(Conjunto A) y NIST (o alternativa documentada)(Conjunto B). Normalizar a $[0, 1]$ y alinear etiquetas entre datasets.

Parte A: Implementación GAN y cGAN

- Implemente una GAN no condicional (puede reutilizar código del Ejercicio 1) y una cGAN. En la cGAN:
 - Incorpore la condición y en G mediante concatenación y/o embedding; documente tamaño de embedding y lugar de inyección.
 - En D , implemente al menos dos formas de condicionamiento: concatenación en la entrada y proyección sobre características intermedias; comparar rendimiento.
- Implementar el esquema de entrenamiento por minibatches estratificados por clase (para evitar sesgo por clases raras).
- Guardar, por época y por clase: pérdidas, varianzas por clase $\overline{\text{Var}}_c$, y métricas de clasificación.

Parte B: Métricas y definiciones (incluir fórmulas)

Defina y calcule las siguientes métricas.

Accuracy por clase (para evaluar cGAN) Para un clasificador C entrenado en datos reales de la base de datos NIST, la **accuracy** de las muestras generadas condicionadas a clase c se define como

$$\text{Accuracy}_c = \frac{1}{N_c} \sum_{i=1}^{N_c} \mathbf{1}\{C(\tilde{x}_i) = c\}, \quad \tilde{x}_i \sim G(z, y = c), \quad (5)$$

donde $\mathbf{1}\{\cdot\}$ es la función indicadora. Reportar Accuracy_c para todas las clases evaluadas.

Cobertura de modos (Mode Coverage) por clase Para clase c , defina la cobertura como la proporción de sub-modos detectados en datos reales que aparecen en las muestras generadas. Proponer un procedimiento cuantitativo (p.ej. clustering de realizaciones reales en K_c clusters y contar clusters con presencia de muestras generadas); formalice la métrica y calculela.

Parte C: Experimentos de transferencia y evaluación

Ejecute los experimentos:

1. Entrenar cGAN en EMNIST (conjunto A).
2. Generar muestras condicionadas a etiquetas presentes en NIST (conjunto B) usando cGAN(A). Calcular Accuracy_c , y cobertura por clase.
3. Entrenar cGAN en NIST (conjunto B) con los mismos hiperparámetros. Calcular métricas análogas.
4. Entrenar un clasificador C sobre B reales y evaluar su matriz de confusión cuando clasifica muestras generadas por cGAN(A) y cGAN(B). Entregar matrix de confusión y medidas derivadas (precision, accuracy, etc.) por clase.

Parte D: Ablaciones y gráficos

1. Ablación 1: Entrenar cGAN con concatenación one-hot y comparar métricas.
2. Ablación 2: Reducir muestras por clase en A (simular baja de datos) y medir efecto en Accuracy_c .
3. Entregar las siguientes gráficas: por clase, curvas de Loss (D/G), Accuracy_c por época, mapas de varianza por clase.

Ejercicio 3: GAN desde fotos de manos (números/letras) — captura, preprocesamiento y generación (Ponderación 1/3)

En este ejercicio se construirá un dataset mediante fotos propias de manos formando dígitos/letras y se entrenará una GAN que genere imágenes coherentes. Requisitos: toda la cadena (captura, preproceso, arquitectura, entrenamiento y métricas) debe implementarse por usted sin dependencias que oculten las operaciones internas.

Parte A: Recolección y preprocesamiento

1. Capturar mínimo 200 fotos propias representando 10 dígitos (0–9) o 10 letras (A–J), con al menos 20 fotos por clase. Documentar las condiciones de captura (ángulo, iluminación, fondo). NOTA: Puede utilizar las fotos que tomó en el ejercicio del módulo 1, considere que puede rotar, trasponer o invertir sus imágenes para no tomar mucho tiempo en la creación de su dataset.
2. Preprocesamiento requerido: detección y recorte de la mano (implemente un método simple basado en umbral y morfología; documento), centrado y normalización. Justificar la elección de usar escala de grises o color.

3. Redimensionar a 64×64 o 128×128 y aplicar la normalización de su elección (justificar).
4. Dividir 80% entrenamiento / 20% prueba; dejar un set de validación adicional (10% del entrenamiento si usted lo desea).

Parte B: Arquitectura y entrenamiento

- Diseñar e implementar una GAN adecuada a su problema.
- Entrenar con al menos dos tamaños de espacio latente $z \in \{8, 32, 64\}$ y comparar resultados cuantitativos.

Parte C: Métricas cuantitativas y varianzas

- a) Generar N muestras por clase y calcular varianza por píxel Var_d y $\overline{\text{Var}}$.
- b) Entrenar un autoencoder con arquitectura propia sobre fotos reales; obtener representaciones $\phi(x) \in \mathbb{R}^m$ y calcular la traza $\text{tr}(\Sigma_c)$ por clase:

$$\text{tr}(\Sigma_c) = \sum_{j=1}^m \text{Var}(\phi_j(x) \mid x \text{ de clase } c).$$

- c) Comparar $\overline{\text{Var}}$ y $\text{tr}(\Sigma_c)$ entre autoencoder y GAN; discutir diferencias y causas (modo colapso, blur, artefactos).
- d) Evaluar utilidad de muestras sintéticas para aumento de datos: reentrenar un clasificador pequeño con (i) solo reales, (ii) reales + sintéticos; comparar accuracy en conjunto test real (entregar pruebas estadísticas de mejora o detrimento).

Parte D: Visualizaciones y entregables

- Mostrar por clase: 10 imágenes reales, 10 imágenes generadas, mapa de varianza y ϕ -representaciones (scatter) si $m \leq 3$.
- Entregar grid 7×7 de decodificaciones desde una cuadrícula en el espacio latente alrededor de una región de interés (si usa espacio 2D para visualización, de lo contrario seleccionar 2 componentes principales de z).

Nota importante

- Reportar la semilla aleatoria usada (si es el caso)